

ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP

CỬ NHÂN NGÀNH CÔNG NGHỆ THÔNG TIN

NGHIÊN CỨU VÀ PHÁT TRIỂN TRỢ LÝ ẢO THÔNG MINH TÍCH HỢP RAG ĐA
PHƯƠNG THỨC CHO HỆ THỐNG E-LEARNING VỚI CÁC NGUỒN HỌC LIỆU
ĐA ĐỊNH DẠNG

RESEARCH AND DEVELOPMENT OF AN INTELLIGENT VIRTUAL ASSISTANT
INTEGRATING MULTIMODAL RAG FOR E-LEARNING SYSTEMS WITH
HETEROGENEOUS LEARNING RESOURCES

Nguyễn Anh Nhật

MSSV: 25210155

Võ Thị Xuân Hoà

MSSV: 25210103

Lớp CN2.K2025.1.CNTT

Giảng viên hướng dẫn: **ThS. Nguyễn Hữu Quyền**

TP. Hồ Chí Minh, 2026



ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ THÔNG TIN

KHOÁ LUẬN TỐT NGHIỆP

CỬ NHÂN NGÀNH CÔNG NGHỆ THÔNG TIN

NGHIÊN CỨU VÀ PHÁT TRIỂN TRỢ LÝ ẢO THÔNG MINH TÍCH HỢP RAG ĐA
PHƯƠNG THỨC CHO HỆ THỐNG E-LEARNING VỚI CÁC NGUỒN HỌC LIỆU
ĐA ĐỊNH DẠNG

RESEARCH AND DEVELOPMENT OF AN INTELLIGENT VIRTUAL ASSISTANT
INTEGRATING MULTIMODAL RAG FOR E-LEARNING SYSTEMS WITH
HETEROGENEOUS LEARNING RESOURCES

Nguyễn Anh Nhật

MSSV: 25210155

Võ Thị Xuân Hoà

MSSV: 25210103

Lớp CN2.K2025.1.CNTT

Giảng viên hướng dẫn: **ThS. Nguyễn Hữu Quyền**

TP. Hồ Chí Minh, 2026

THÔNG TIN HỘI ĐỒNG CHẤM KHÓA LUẬN TỐT NGHIỆP

Hội đồng chấm khóa luận tốt nghiệp, thành lập theo Quyết định số
ngày của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

LỜI CẢM ƠN

Nhóm xin gửi lời cảm ơn tới ThS. Nguyễn Hữu Quyền, người đã trực tiếp tận tình hướng dẫn nhóm trong suốt quá trình thực hiện khóa luận. Nhóm vô cùng biết ơn sự tận tình chỉ dẫn của Thầy trong quá trình nhóm thực hiện đề tài này. Bước đầu tiếp cận các công nghệ mới, nhóm còn nhiều thiếu sót về mặt kiến thức cũng như kinh nghiệm thực tiễn nên không tránh khỏi nhiều sai sót. Những nhận xét, góp ý chân tình của Thầy chính là cơ sở để nhóm có thể cải tiến và hoàn thiện đề tài này một cách tốt nhất. Nếu không có những lời chỉ bảo tận tình của Thầy thì khóa luận này của nhóm rất khó để thực hiện.

Trong quá trình thực hiện khóa luận, nhóm có thể không tránh khỏi được sai sót, chúng em kính mong nhận được sự góp ý, hướng dẫn của Thầy để có thể hoàn thiện khóa luận hơn nữa.

Chúng em xin gửi lời cảm ơn chân thành nhất đến Thầy.

TP. Hồ Chí Minh, năm 2026

Nhóm sinh viên thực hiện

Nguyễn Anh Nhật – MSSV: 25210155

Võ Thị Xuân Hoà – MSSV: 25210103

NỘI DUNG

THÔNG TIN HỘI ĐỒNG CHẤM KHÓA LUẬN TỐT NGHIỆP	i
LỜI CẢM ƠN	ii
DANH SÁCH HÌNH ẢNH	v
DANH SÁCH BẢNG BIỂU	vii
DANH MỤC TỪ VIẾT TẮT	viii
DANH MỤC TỪ TẠM DỊCH	ix
TÓM TẮT KHOÁ LUẬN	1
1 TỔNG QUAN ĐỀ TÀI	2
1.1 Lý do chọn đề tài	2
1.2 Các nghiên cứu liên quan	3
1.2.1 Sinh tăng cường truy xuất và mở rộng đa phương thức	3
1.2.2 Truy xuất trên tài liệu giàu thị giác	4
1.2.3 Truy xuất và hỏi đáp trên video	4
1.2.4 Sinh tăng cường truy xuất trong giáo dục	4
1.2.5 Đánh giá hệ thống sinh tăng cường truy xuất	5
1.2.6 Tổng hợp nghiên cứu và khoảng trống	5
1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu	8
1.3.1 Mục tiêu nghiên cứu	8
1.3.2 Câu hỏi nghiên cứu	8
1.3.3 Đối tượng nghiên cứu	9
1.3.4 Phạm vi nghiên cứu	9
1.4 Phương pháp nghiên cứu	9
1.5 Những điểm mới của đề tài	10
1.6 Cấu trúc khóa luận	11
2 CƠ SỞ LÝ THUYẾT	12
2.1 Học liệu đa định dạng và siêu dữ liệu học liệu	12
2.2 Mô hình ngôn ngữ lớn và mô hình biểu diễn vector	13
2.3 Sinh tăng cường truy xuất	13
2.3.1 Sinh tăng cường truy xuất	13

2.3.2	Mở rộng đa phương thức	13
2.4	Truy xuất thông tin	14
2.4.1	Truy xuất dày	14
2.4.2	Truy xuất thưa và BM25	14
2.4.3	Hợp nhất thứ hạng nghịch đảo	15
2.4.4	Bộ xếp hạng lại	15
2.4.5	Truy vấn mở rộng bằng tài liệu giả định	15
2.5	Xử lý học liệu đa định dạng	16
2.5.1	Phân tích bố cục tài liệu	16
2.5.2	Nhận dạng ký tự quang học	16
2.5.3	Nhận dạng giọng nói tự động	16
2.5.4	Bấm ảnh	16
2.5.5	Phân đoạn văn bản	17
2.6	Sinh câu trả lời có căn cứ	17
2.7	Đánh giá hệ thống truy xuất và sinh	17
2.7.1	Các chỉ số truy xuất	17
2.7.2	Đánh giá hệ thống sinh tăng cường truy xuất	18
2.7.3	Khoảng tin cậy bằng phương pháp lấy mẫu lại	18
3	PHƯƠNG PHÁP THỰC HIỆN	19
3.1	Kiến trúc tổng thể	19
3.2	Biểu diễn đối tượng tri thức và siêu dữ liệu	20
3.3	Tiền xử lý học liệu dạng tài liệu, bảng và ảnh	22
3.3.1	Phân tích tài liệu	22
3.3.2	Nhận dạng ký tự dự phòng	22
3.3.3	Phân đoạn văn bản	23
3.3.4	Loại trùng và cập nhật tăng dần	23
3.4	Tiền xử lý video bài giảng	23
3.5	Biểu diễn vector và lập chỉ mục	26
3.6	Truy xuất lai đa phương thức	27
3.7	Sinh câu trả lời có căn cứ	30
3.7.1	Lập kế hoạch truy vấn	30
3.7.2	Ngữ cảnh và câu lệnh dẫn dắt	31
3.7.3	Trả lời dựa trên ảnh	31
3.7.4	Giao diện lập trình ứng dụng	32
3.8	Khung đánh giá truy xuất không rò rỉ dữ liệu	33
3.9	Hạn chế của thiết kế hiện tại	34

4	THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN	36
4.1	Mục tiêu và phạm vi của thực nghiệm	36
4.2	Môi trường thực nghiệm	37
4.3	Dữ liệu thực nghiệm	37
4.3.1	Kho học liệu	37
4.3.2	Bộ câu hỏi và nhãn chuẩn	38
4.3.3	Tập câu hỏi được chấm điểm	39
4.4	Cấu hình các hệ thống được so sánh	39
4.5	Kết quả và nhận xét	39
4.5.1	Kết quả truy xuất trung bình	39
4.5.2	Kiểm định thống kê	40
4.5.3	Tỷ lệ trùng	41
4.5.4	Kết quả theo nhóm câu hỏi và theo độ khó	42
4.5.5	Kết quả sinh câu trả lời (generation-level)	42
4.6	Phân tích và thảo luận	45
4.7	Ưu điểm và hạn chế	46
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	48
5.1	Kết luận	48
5.2	Hướng phát triển	49
	TÀI LIỆU THAM KHẢO	54

DANH SÁCH HÌNH ẢNH

3.1	Kiến trúc tổng thể của hệ thống trợ lý ảo	20
3.2	Luồng xử lý video bài giảng	24
3.3	Luồng truy xuất lai đa phương thức	28
4.1	So sánh P/R/F1 tại $K \in \{5, 10\}$ giữa ba hệ thống truy xuất	40
4.2	F1@10 theo nhóm câu hỏi, Cơ sở so với Lai + XHL	42
4.3	F1@10 theo độ khó, Cơ sở so với Lai + XHL	43

DANH SÁCH BẢNG BIỂU

1.1	Tổng hợp một số công trình liên quan	6
3.1	Các trường siêu dữ liệu được ghi cho từng đối tượng tri thức	21
3.2	Kích thước đoạn và độ chồng lấp theo loại tệp (đơn vị: ký tự)	23
3.3	Các mô hình của họ Qwen3 được hệ thống sử dụng	26
3.4	Khoản thưởng cộng vào điểm theo loại nội dung	29
3.5	Các sự kiện truyền theo luồng của điểm cuối hỏi đáp	32
4.1	Số tệp đã được lập chỉ mục, theo môn học và loại tệp (độ phủ 69/69, không lỗi)	38
4.2	Phân bố 400 câu hỏi theo nhóm và theo độ khó	38
4.3	Cấu hình của ba hệ thống truy xuất được so sánh	39
4.4	Điểm trung bình macro trên 400 câu, ba hệ thống (xem tên đầy đủ ở Bảng 4.3)	40
4.5	Hiệu số và khoảng tin cậy 95% (lấy mẫu lại ghép cặp, 400 bản ghi, 10 000 lần lấy mẫu)	41
4.6	Tỷ lệ trúng tại K trên 400 câu, ba hệ thống	42
4.7	F1@10 theo nhóm câu hỏi, ba hệ thống	43
4.8	F1@10 theo độ khó, ba hệ thống	44
4.9	Kết quả sinh câu trả lời trên 400 câu, cấu hình Lai + XHL, chỉ ngữ cảnh văn bản	44
4.10	Độ phủ/độ chính xác theo tệp, theo nhóm câu hỏi (sinh câu trả lời)	45
4.11	Độ phủ/độ chính xác theo tệp, theo độ khó (sinh câu trả lời)	45

DANH MỤC TỪ VIẾT TẮT

ANN	Approximate Nearest Neighbor
API	Application programming interface
ASR	Automatic speech recognition
CLI	Command-line interface
CPU	Central processing unit
LLM	Large Language Model
LOM	Learning object metadata
MPS	Metal Performance Shaders
OCR	Optical character recognition
RAG	Retrieval-augmented generation
RAGAs	Retrieval Augmented Generation Assessment
RRF	Reciprocal rank fusion
SSE	Server-sent events
VLM	Vision-language model

DANH MỤC TỪ TẠM DỊCH

Biểu diễn vector	embedding
Băm trung bình	average hash
Bản phiên âm	transcript
Bộ xếp hạng lại	reranker
Bộ xử lý trung tâm	Central processing unit
Bộ đánh giá chuẩn	benchmark
Câu lệnh	prompt
Giao diện dòng lệnh	Command-line interface
Giao diện lập trình ứng dụng	Application programming interface
Giá trị khởi tạo ngẫu nhiên	random seed
Hệ thống cơ sở	baseline
Hợp nhất thứ hạng nghịch đảo	Reciprocal rank fusion
Khung tăng tốc đồ họa của Apple	Metal Performance Shaders
Luồng xử lý	pipeline
Lấy mẫu lại	bootstrap
Mô hình ngôn ngữ lớn	Large Language Model
Mô hình ngôn ngữ thị giác	Vision-language model
Mốc thời gian	timestamp
Nhãn chuẩn	ground truth
Nhóm câu hỏi	category
Nhận dạng giọng nói tự động	Automatic speech recognition
Nhận dạng ký tự quang học	Optical character recognition

Phân đoạn văn bản	chunking
RAG đa phương thức	Multimodal RAG
Sinh tăng cường truy xuất	Retrieval-augmented generation
Siêu dữ liệu	metadata
Siêu dữ liệu đối tượng học tập	Learning object metadata
Sự kiện do máy chủ gửi	Server-sent events
Thí nghiệm loại trừ	ablation study
Truy xuất dày	dense retrieval
Truy xuất lai	hybrid retrieval
Truy xuất thưa	sparse retrieval
Tìm kiếm lân cận xấp xỉ gần nhất	Approximate Nearest Neighbor
Tập vector	collection
Tệp đi kèm	sidecar
Tỷ lệ trúng	hit rate
Điểm lưu trạng thái	checkpoint
Đánh giá đầu-cuối	end-to-end evaluation
Đơn vị văn bản	token
Độ liên quan của câu trả lời	Answer Relevance
Độ trung thực với ngữ cảnh	faithfulness

TÓM TẮT KHOÁ LUẬN

Khoá luận nghiên cứu và xây dựng một trợ lý ảo cho hệ thống e-learning dựa trên sinh tăng cường truy xuất (Retrieval-augmented generation - RAG). Trợ lý trả lời câu hỏi của người học từ học liệu đa định dạng gồm tài liệu PDF, DOCX, PPTX và video bài giảng, kèm trích dẫn có vị trí cụ thể (số trang hoặc thời điểm trong video) để người học kiểm chứng.

Hệ thống thuộc hướng RAG đa phương thức (Multimodal RAG): học liệu được xử lý thành hai không gian vector, một cho văn bản và một cho ảnh, kèm một chỉ mục từ vựng BM25. Với video, hệ thống kết hợp nhận dạng giọng nói tự động (Automatic speech recognition - ASR), nhận dạng ký tự quang học (Optical character recognition - OCR) và chọn lọc khung hình đại diện. Ở bước truy xuất, hệ thống áp dụng truy xuất lai (hybrid retrieval) trên các nguồn văn bản, từ vựng và ảnh, hợp nhất bằng hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF) và lọc theo môn học. Câu trả lời được sinh kèm trích dẫn.

Chúng tôi đánh giá khả năng truy xuất bằng một quy trình không rò rỉ dữ liệu trên bộ 400 câu hỏi về ba môn học, so sánh ba cấu hình truy xuất: hệ thống cơ sở (baseline) chỉ truy xuất trên văn bản, hệ thống lai đa phương thức (BM25 và truy xuất trên ảnh) chưa qua bộ xếp hạng lại (reranker), và hệ thống lai có thêm bộ xếp hạng lại (Qwen3-Reranker-0.6B). Điểm được tính trên toàn bộ 400 câu, vì kho học liệu dùng cho lần đánh giá này đạt độ phủ 100% đối với bộ câu hỏi. Kết quả cho thấy riêng việc thêm BM25 và truy xuất trên ảnh, khi chưa xếp hạng lại, không cải thiện so với hệ thống cơ sở. Tuy nhiên, hệ thống lai có thêm bộ xếp hạng lại vượt hệ thống cơ sở với khoảng tin cậy lấy mẫu lại (bootstrap) 95% không chứa 0 ở phần lớn chỉ số tại $K = 5$ và $K = 10$ — bằng chứng thống kê đầu tiên trong khoá luận cho thấy cấu hình đề xuất cải thiện chất lượng truy xuất. Với cấu hình tốt nhất này, chúng tôi cũng đánh giá chất lượng câu trả lời và ngữ cảnh truy xuất bằng bốn chỉ số tham khảo từ RAGAs: độ trung thực với ngữ cảnh (faithfulness), độ liên quan của câu trả lời (answer relevance), độ chính xác ngữ cảnh (context precision) và độ thu hồi ngữ cảnh (context recall). Kết quả được báo cáo cùng các giới hạn của phạm vi thực nghiệm ở **Chương 5**.

Chương 1

TỔNG QUAN ĐỀ TÀI

Tóm tắt chương

Trong chương này, chúng tôi trình bày lý do chọn đề tài, các công trình nghiên cứu liên quan, mục tiêu, đối tượng và phạm vi nghiên cứu, phương pháp nghiên cứu và những điểm mới của đề tài. Cuối cùng, chúng tôi nêu cấu trúc của khóa luận.

1.1 Lý do chọn đề tài

Xét một môn học trong hệ thống e-learning. Cùng một khái niệm có thể được giới thiệu trong video bài giảng, được định nghĩa trong slide, được giải thích chi tiết trong giáo trình dạng PDF và được kiểm tra qua bài tập. Khi người học đặt câu hỏi, câu trả lời vì thế có thể nằm rải rác trong nhiều tài nguyên thuộc các định dạng khác nhau, và người học phải tự tìm trong từng video, từng bộ slide hay từng tài liệu. Việc tìm kiếm theo từ khóa dễ bỏ sót khi cách diễn đạt của câu hỏi khác với tài liệu: khảo sát của Furnas và cộng sự trên năm miền ứng dụng cho thấy xác suất hai người chọn cùng một thuật ngữ để gọi cùng một đối tượng thấp hơn 0,20 trong mọi trường hợp được khảo sát [10].

Các mô hình ngôn ngữ lớn (Large Language Model - LLM) có thể trả lời câu hỏi bằng ngôn ngữ tự nhiên, nhưng gặp các vấn đề như sinh nội dung sai lệch, kiến thức lỗi thời và quá trình suy luận thiếu minh bạch, không truy vết được [13]. Sinh tăng cường truy xuất (Retrieval-augmented generation - RAG) nổi lên như một giải pháp hứa hẹn cho các vấn đề này bằng cách đưa tri thức lấy từ một kho ngoài vào quá trình sinh [20, 13]. Chúng tôi chọn hướng này cho một trợ lý học tập vì trợ lý cần trả lời kèm nguồn để người học có thể kiểm chứng.

Học liệu không chỉ có văn bản. Tài liệu PDF và slide chứa hình, bảng và bố cục,

và các hệ thống truy xuất chủ yếu dựa vào văn bản trích xuất khó khai thác hiệu quả từ các nguồn đó [9]; các hệ thống RAG chỉ dựa trên văn bản không thể tận dụng thông tin thị giác như bố cục và hình ảnh, vốn đóng vai trò quan trọng trong tài liệu nhiều phương thức [33]. Video bài giảng là một dạng học liệu khác: các phương pháp RAG trước đây chủ yếu tập trung vào văn bản, một số công trình gần đây xét đến ảnh, và phần lớn bỏ qua video dù đây là nguồn tri thức đa phương thức giàu ngữ cảnh [17]. Hướng RAG đa phương thức đã được khảo sát có hệ thống [1], kể cả khảo sát riêng cho bài toán hiểu tài liệu [12].

Trong giáo dục, RAG đã được khảo sát có hệ thống [22]. Đã có công trình kết hợp thị giác và ngôn ngữ trong một nền tảng dạy học [14], và công trình đề xuất khung RAG đa phương thức cho hỏi đáp trên video bài giảng [31].

Từ các quan sát trên, trong khóa luận này chúng tôi nghiên cứu và xây dựng một trợ lý ảo cho hệ thống e-learning dựa trên RAG đa phương thức. Trợ lý truy xuất bằng chứng từ học liệu đa định dạng (tài liệu PDF, DOCX, PPTX và video bài giảng), trả lời câu hỏi của người học kèm trích dẫn có vị trí cụ thể (số trang hoặc thời điểm trong video), đồng thời chúng tôi đánh giá chất lượng truy xuất của hệ thống một cách có kiểm soát và báo cáo trung thực kết quả thu được.

1.2 Các nghiên cứu liên quan

1.2.1 Sinh tăng cường truy xuất và mở rộng đa phương thức

Lewis và cộng sự [20] chỉ ra rằng các mô hình ngôn ngữ tiền huấn luyện lớn tuy lưu được tri thức thực tế trong tham số và đạt kết quả tốt nhất khi được tinh chỉnh cho các tác vụ hạ nguồn, nhưng khả năng truy cập và thao tác chính xác tri thức của chúng còn hạn chế, khiến hiệu năng trên các tác vụ cần nhiều tri thức kém hơn so với các kiến trúc chuyên biệt; họ đề xuất RAG để khắc phục hạn chế này. Gao và cộng sự [13] khảo sát RAG cho LLM và nêu ba thách thức của LLM mà RAG hướng tới: sinh nội dung sai lệch, kiến thức lỗi thời và quá trình suy luận không minh bạch, không truy vết được.

Đối với ảnh và văn bản, Chen và cộng sự [4] đề xuất MuRAG, một mô hình sinh được tăng cường bằng truy xuất đa phương thức cho bài toán hỏi đáp mở trên ảnh và văn bản. Abootorabi và cộng sự [1] khảo sát toàn diện RAG đa phương thức, bao gồm các bộ dữ liệu, thước đo, phương pháp đánh giá và các đổi mới trong truy xuất, hợp nhất, bổ sung ngữ cảnh và sinh. Các công trình này cung cấp nền tảng khái niệm cho khóa luận; chúng tôi áp dụng vào bối cảnh học liệu của một khóa học, nơi câu trả lời phải kèm vị trí cụ thể trong tệp nguồn.

1.2.2 Truy xuất trên tài liệu giàu thị giác

Huang và cộng sự [15] đề xuất LayoutLMv3, một mô hình tiền huấn luyện cho bài toán hiểu tài liệu với mục tiêu che thống nhất trên cả văn bản và ảnh. Faysse và cộng sự [9] nhận xét rằng các hệ thống truy xuất hiện đại chủ yếu dựa vào văn bản trích xuất từ trang tài liệu, thường qua các quy trình dài và dễ hỏng, nên khó khai thác các tín hiệu thị giác; họ đề xuất ColPali để truy xuất tài liệu bằng các mô hình ngôn ngữ thị giác (Vision-language model - VLM). Yu và cộng sự [33] đề xuất VisRAG, một quy trình RAG dựa trên VLM trong đó tài liệu được biểu diễn trực tiếp như ảnh, được truy xuất và sau đó được VLM dùng để sinh câu trả lời. Tanaka và cộng sự [30] đề xuất VDocRAG cho hỏi đáp trên tập tài liệu giàu thị giác ở nhiều định dạng (như PDF và PPTX), hiểu trực tiếp tài liệu ở dạng ảnh thống nhất để tránh mất thông tin do phân tích tài liệu sang văn bản. Khảo sát của Gao và cộng sự [12] nêu rằng các quy trình dựa trên OCR đưa văn bản vào LLM thì mất chi tiết cấu trúc, còn các LLM đa phương thức gốc gặp khó khăn trong việc mô hình hóa ngữ cảnh.

Các công trình trên đều xoay quanh ảnh trang của tài liệu. Hệ thống của chúng tôi duy trì đồng thời hai chỉ mục, một cho văn bản (kèm văn bản nhận dạng từ ảnh) và một cho ảnh, để một câu hỏi có thể khớp bằng cả từ vựng lẫn nội dung hình ảnh, và mở rộng phạm vi sang video bài giảng.

1.2.3 Truy xuất và hỏi đáp trên video

Jeong và cộng sự [17] đề xuất VideoRAG, khung truy xuất động các video theo mức độ liên quan với câu hỏi và dùng cả thông tin thị giác lẫn văn bản; khung này có cơ chế chọn khung hình để trích ra tập con giàu thông tin nhất của các video rất dài và có phương pháp trích xuất văn bản khi video không có phụ đề. Để có văn bản từ âm thanh của video, khóa luận dựa vào ASR; Whisper là một mô hình như vậy, được huấn luyện với 680 000 giờ dữ liệu giám sát đa ngôn ngữ và đa tác vụ, và tổng quát hóa tốt theo cách chuyển giao không mẫu [26]. Riêng với video bài giảng, Tanner và cộng sự [31] đề xuất khung RAG đa phương thức để nâng cao hỏi đáp trên loại video này. Khóa luận cũng dùng bản phiên âm (transcript) và khung hình được chọn của video, nhưng đặt chúng cùng chỉ mục và bộ truy xuất với học liệu dạng tài liệu của cùng khóa học.

1.2.4 Sinh tăng cường truy xuất trong giáo dục

Li và cộng sự [22] thực hiện một khảo sát có hệ thống về RAG cho các ứng dụng giáo dục. Gokhman và cộng sự [14] đề xuất VL-RAG, một nền tảng dạy học kết

hợp thành phần thị giác và ngôn ngữ với truy xuất thông tin trên một cơ sở dữ liệu chứa các đáp án và hình ảnh, nhằm tạo trải nghiệm tương tác cho người học và giảm sự phụ thuộc vào sự giám sát liên tục của con người. Trong khóa luận này, hệ thống của chúng tôi truy xuất trực tiếp trên học liệu gốc của khóa học và trích dẫn vị trí trong tệp gốc.

1.2.5 Đánh giá hệ thống sinh tăng cường truy xuất

Es và cộng sự [8] đề xuất RAGAs, một khung đánh giá các hệ thống RAG với các chỉ số cho khả năng truy xuất, khả năng khai thác ngữ cảnh một cách trung thực của LLM và chất lượng của phần sinh. Đối với riêng khâu truy xuất, các chỉ số Precision, Recall và F1 là cách đo chuẩn trong truy xuất thông tin [24]. Trong khóa luận này, chúng tôi đánh giá khâu truy xuất bằng các chỉ số đó và bổ sung khoảng tin cậy thống kê; phần đánh giá câu trả lời và ngữ cảnh truy xuất tham khảo bốn chỉ số của RAGAs: độ trung thực với ngữ cảnh (faithfulness), độ liên quan của câu trả lời (answer relevance), độ chính xác ngữ cảnh (context precision) và độ thu hồi ngữ cảnh (context recall) (**Chương 4, Mục 4.5.5**).

1.2.6 Tổng hợp nghiên cứu và khoảng trống

Bảng 1.1 đối chiếu một số công trình tiêu biểu đã được trình bày ở trên. Cột hạn chế chỉ nêu nội dung được bài báo trực tiếp ghi nhận; khi công trình không báo cáo hạn chế riêng, điều đó được ghi rõ.

Bảng 1.1: Tổng hợp một số công trình liên quan

Công trình	Vấn đề/loại dữ liệu	Tập dữ liệu và nhiệm vụ	Phương pháp	Cách đánh giá	Hạn chế do bài báo nêu	Liên hệ với đề tài
Lewis và cộng sự [20]	RAG cho tác vụ NLP cần tri thức ngoài.	Natural Questions, TriviaQA, WebQuestions, CuratedTrec và các tác vụ sinh câu hỏi, truy xuất, kiểm chứng thông tin.	Kết hợp mô hình sinh seq2seq với bộ truy xuất dày (dense retrieval) trên chỉ mục Wikipedia.	So sánh với các mô hình nền trên các tác vụ hỏi đáp và NLP cần tri thức bằng thước đo tương ứng của từng tác vụ.	Bài nêu việc truy vết nguồn và cập nhật tri thức là vấn đề còn mở với LLM; đây là động cơ nghiên cứu, không được bài trình bày như hạn chế thực nghiệm của RAG.	Cơ sở cho kiến trúc RAG và đánh giá truy xuất, nhưng không xét học liệu đa phương thức của các môn học.
MuRAG [4]	Hỏi đáp mở cần kết hợp thông tin từ ảnh và văn bản.	WebQA và MultimodalQA; truy xuất và suy luận trên bằng chứng ảnh-văn bản.	Bộ nhớ đa phương thức bên ngoài; huấn luyện kết hợp mục tiêu tương phản và sinh.	Độ chính xác trả lời trên hai bộ dữ liệu, ở thiết lập distractor và full-wiki; có phân tích thủ công đầu ra.	Phân tích lỗi của bài ghi nhận khó khăn với đối tượng hiếm, cảnh phức tạp và OCR; tác giả xác định hiểu thị giác là điểm nghẽn.	Cho thấy lý do cần truy xuất thị giác, nhưng khác miền học liệu khóa học và cách trích dẫn vị trí nguồn.
ColPali [9]	Truy xuất trang tài liệu giàu bố cục, bảng và hình ảnh.	ViDoRe gồm các tác vụ truy xuất ở cấp trang trên nhiều miền và ngôn ngữ.	Mã hóa ảnh trang thành nhiều vector và so khớp bằng late interaction.	Các thước đo truy xuất của ViDoRe, gồm nDCG@5 và Recall@1; bài cũng báo cáo độ trễ.	Bài nêu đánh đổi lưu trữ do cần giữ vector cho các patch ảnh; giảm số patch làm giảm hiệu năng trong các thí nghiệm ablation.	Liên quan trực tiếp đến nhánh truy xuất ảnh trang, nhưng bộ đánh giá chuẩn (benchmark) của bài không phải corpus ba môn tiếng Việt.
VisRAG [33]	RAG trên tài liệu đa phương thức, nơi bố cục và hình ảnh quan trọng.	ArxivQA, ChartQA, DocVQA, InfoVQA, PlotQA và SlideVQA.	Dùng VLM mã hóa trực tiếp ảnh trang để truy xuất, sau đó dùng mô hình thị giác-ngôn ngữ để sinh.	MRR@10 và Recall@10 cho truy xuất; độ chính xác câu trả lời cho sinh.	Bài ghi nhận hiệu năng sinh giảm khi tăng số trang truy xuất; các VLM mã nguồn mở còn khó suy luận qua nhiều trang và xử lý context nhiều.	Cung cấp đối chiếu cho xử lý PDF/PPT bằng ảnh; đề tài này đồng thời duy trì nhánh văn bản và đánh giá trên học liệu khóa học.
VideoRAG [17]	Truy xuất động video và khai thác đồng thời tín hiệu hình ảnh, văn bản.	WikiHowQA được liên kết với video HowTo100M và dữ liệu tổng hợp cho hỏi đáp trên video.	Dùng biểu diễn video đa phương thức để truy xuất video theo câu hỏi và đưa nội dung liên quan vào bước sinh.	Recall@K cho truy xuất; ROUGE-L, BLEU-4, BERTScore và G-Eval cho sinh.	Tác giả nêu dữ liệu đánh giá RAG trên video còn hạn chế và cần phát triển, công bố thêm bộ đánh giá chuẩn.	Liên quan đến nhánh video, nhưng đề tài đánh giá truy xuất trên bản phiên âm/khung hình đã lập chỉ mục cùng các tài liệu môn học.

Công trình	Vấn đề/loại dữ liệu	Tập dữ liệu và nhiệm vụ	Phương pháp	Cách đánh giá	Hạn chế do bài báo nêu	Liên hệ với đề tài
RAGAs [8]	Đánh giá tự động các khía cạnh truy xuất context và sinh câu trả lời trong RAG.	WikiEval, với các chỉ số đo trung thực với ngữ cảnh, độ liên quan của câu trả lời và độ liên quan ngữ cảnh.	Bộ chỉ số tham chiếu-tự-đo dùng mô hình ngôn ngữ để ước lượng các khía cạnh chất lượng RAG.	Báo cáo các chỉ số đánh giá chất lượng phần sinh và ngữ cảnh trong RAG.	Kết quả phụ thuộc vào thiết lập và năng lực của mô hình ngôn ngữ được sử dụng; cần xem xét mức phù hợp của khung đánh giá.	Là nguồn tham khảo cho các chỉ số đánh giá phần sinh và context được dùng trong khóa luận.
Li và cộng sự [22]	Tổng quan RAG trong các bối cảnh giáo dục.	Tổng hợp 51 nghiên cứu về mục tiêu, bối cảnh học tập và ứng dụng giáo dục.	Khảo sát có hệ thống và phân loại các thành phần kỹ thuật, ứng dụng, thách thức.	Tổng hợp và đối chiếu các nghiên cứu đã công bố; không phải bộ đánh giá chuẩn so sánh một hệ thống RAG đơn lẻ.	Bài nêu các thách thức của RAG giáo dục, trong đó có khả năng đa phương thức còn hạn chế; không báo cáo hạn chế thực nghiệm của một hệ thống đơn lẻ.	Đặt đề tài vào bối cảnh RAG giáo dục; khóa luận tập trung vào corpus học liệu đa định dạng của ba môn cụ thể.

Các công trình trên cho thấy RAG đa phương thức, truy xuất tài liệu thị giác, truy xuất video và RAG trong giáo dục đều đã được nghiên cứu. Vì vậy, khóa luận không xem việc “chưa có RAG đa phương thức” là khoảng trống. Phần thực nghiệm tập trung so sánh ba cấu hình truy xuất trên cùng corpus học liệu tiếng Việt thuộc ba môn và cùng bộ 400 câu hỏi; kết luận được giới hạn trong corpus, bộ đánh giá chuẩn và thiết lập này.

1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu

1.3.1 Mục tiêu nghiên cứu

Xây dựng và đánh giá một trợ lý ảo cho hệ thống e-learning dựa trên RAG đa phương thức, có khả năng truy xuất bằng chứng từ học liệu đa định dạng (video bài giảng, slide, tài liệu PDF và DOCX) và trả lời câu hỏi của người học kèm bằng chứng có vị trí cụ thể. Cụ thể, khóa luận có bốn mục tiêu:

1. Tổ chức học liệu đa định dạng thành một kho tri thức thống nhất, trong đó mỗi đơn vị tri thức giữ được vị trí của nó trong tệp nguồn.
2. Xây dựng bộ truy xuất kết hợp nhiều nguồn (văn bản, từ vựng, ảnh) và có lọc theo môn học.
3. Sinh câu trả lời có căn cứ, kèm trích dẫn có vị trí.
4. Đánh giá chất lượng truy xuất bằng một quy trình không rò rỉ dữ liệu, kèm kiểm định thống kê và báo cáo trung thực.

1.3.2 Câu hỏi nghiên cứu

Từ mục tiêu nghiên cứu, khóa luận tập trung trả lời hai câu hỏi sau:

- RQ1** Trên cùng kho học liệu và bộ 400 câu hỏi, ba cấu hình truy xuất baseline, `hybrid_norerank` và `hybrid_rerank_fixed` khác nhau như thế nào về Precision, Recall, F1 và tỷ lệ trúng (hit rate) tại $K \in \{1, 5, 10\}$?
- RQ2** Kết quả truy xuất của ba cấu hình thay đổi như thế nào theo nhóm câu hỏi (*category*) và độ khó (*difficulty*)? Phân tích này được trình bày theo hướng mô tả.

1.3.3 Đối tượng nghiên cứu

Chúng tôi tập trung nghiên cứu trên các đối tượng sau:

- Học liệu đa định dạng thuộc ba môn học: Cấu trúc rời rạc, Nhập môn Lập trình, và Cấu trúc dữ liệu và Giải thuật; gồm video bài giảng, slide, tài liệu PDF và DOCX.
- RAG đa phương thức
- Truy xuất thông tin trên văn bản và ảnh, và cách hợp nhất các nguồn
- Sinh câu trả lời có căn cứ kèm trích dẫn có vị trí
- Đánh giá truy xuất không rò rỉ dữ liệu

1.3.4 Phạm vi nghiên cứu

Về dữ liệu, khóa luận giới hạn ở ba môn học thuộc lĩnh vực công nghệ thông tin: Cấu trúc rời rạc, Nhập môn Lập trình, và Cấu trúc dữ liệu và Giải thuật, với 69 tệp học liệu tại thời điểm đánh giá (21 tệp PDF, 7 tệp PPTX, 7 tệp PPT, 4 tệp DOCX và 30 video — **Mục 4.3**) và bộ 400 câu hỏi đánh giá. Toàn bộ câu hỏi và học liệu đều bằng tiếng Việt (đối chiếu trực tiếp nội dung học liệu xác nhận không có tệp nào bằng tiếng Anh thuần, dù một số thuật ngữ kỹ thuật được chú thích song ngữ trong slide, ví dụ “CON TRỎ – POINTER”); người dùng chính là sinh viên. Về nội dung, khóa luận tập trung vào khâu truy xuất và cơ chế sinh câu trả lời có căn cứ; chất lượng của câu trả lời được sinh và ngữ cảnh truy xuất được đánh giá trên một cấu hình truy xuất bằng các chỉ số tham khảo từ RAGAs (**Mục 4.5.5**). Khóa luận không bao gồm: huấn luyện LLM từ đầu, hỗ trợ mọi ngành học, chấm điểm tự động bài tự luận, xây dựng một hệ thống quản lý học tập hoàn chỉnh, cá nhân hóa sâu theo lịch sử dài hạn, kiến trúc nhiều tác tử phức tạp và việc thay thế vai trò của giảng viên. Việc lập chỉ mục riêng cho bài tập, kiểm soát mức độ gợi ý và quyền truy cập đáp án, cùng đồ thị tri thức liên kết các nguồn được xem là hướng phát triển (**Chương 5**).

1.4 Phương pháp nghiên cứu

Chúng tôi thực hiện đề tài theo các bước sau. Thứ nhất, tìm hiểu các công trình về RAG, RAG đa phương thức, truy xuất trên tài liệu giàu thị giác, truy xuất và hỏi đáp trên video, và ứng dụng RAG trong giáo dục. Thứ hai, thiết kế và hiện thực hệ thống gồm luồng nạp và tiền xử lý học liệu, chỉ mục, bộ truy xuất, bộ sinh câu

trả lời và giao diện lập trình ứng dụng (Application programming interface - API). Thứ ba, xây dựng quy trình đánh giá truy xuất không rõ ràng dữ liệu, trong đó truy vấn và nhãn chuẩn (ground truth) được tách riêng. Thứ tư, thực nghiệm so sánh hệ thống đề xuất với một hệ thống cơ sở trên cùng bộ câu hỏi, bổ sung kiểm định thống kê để xác định các khác biệt có ý nghĩa. Cuối cùng, chúng tôi phân tích kết quả, nêu rõ hạn chế và trạng thái của các thí nghiệm chưa thực hiện.

1.5 Những điểm mới của đề tài

Trong khóa luận này, chúng tôi trình bày những đóng góp sau. Các đóng góp mô tả những gì đã được hiện thực và kiểm chứng trong phạm vi khóa luận; chúng tôi không khẳng định đó là những điều chưa có công trình nào làm.

- Một luồng nạp học liệu đa định dạng thành kho tri thức thống nhất, gồm hai chỉ mục vector (văn bản và ảnh) cùng một chỉ mục từ vựng, trong đó mỗi đơn vị tri thức giữ vị trí trong tệp nguồn (số trang, số slide hoặc thời điểm trong video).
- Một luồng xử lý (pipeline) video bài giảng thành các cửa sổ 30 giây, mỗi cửa sổ có bản phiên âm và các khung hình đại diện: khung hình gần trùng bị loại bằng băm trung bình (average hash), và việc chọn khung hình còn dùng điểm kết hợp mức thay đổi thị giác, mức thay đổi văn bản nhận dạng được, biên cảnh và độ phủ thời gian (với tham số mặc định, chỉ bước loại trùng thực sự làm thay đổi tập khung hình được giữ); cùng cơ chế lưu trạng thái để xử lý các video dài có thể tiếp tục sau khi bị gián đoạn.
- Một bộ truy xuất lai (hybrid retrieval) đa phương thức kết hợp truy xuất dày trên văn bản, truy xuất thưa (sparse retrieval) và truy xuất dày trên ảnh, hợp nhất bằng phương pháp hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF), có lọc theo môn học, đa dạng theo tệp, mở rộng và nén ngữ cảnh.
- Một cơ chế sinh câu trả lời có căn cứ với trích dẫn có vị trí, chuyển sang mô hình thị giác khi có ảnh trang hoặc ảnh hình của tài liệu, và API truyền phát câu trả lời kèm đường dẫn mở đúng đoạn video hoặc đúng trang tài liệu.
- Một quy trình đánh giá truy xuất không rõ ràng dữ liệu, kèm báo cáo trung thực gồm kiểm định thống kê, độ phủ của kho học liệu và trạng thái của các thí nghiệm chưa thực hiện. Trên thực nghiệm với kho học liệu đạt độ phủ 100%, cấu hình lai đa phương thức có xếp hạng lại vượt hệ thống cơ sở với khoảng

tin cậy lấy mẫu lại (bootstrap) không chứa 0 ở phần lớn chỉ số tại $K = 5$ và $K = 10$; riêng việc hợp nhất đa phương thức khi chưa xếp hạng lại thì không cải thiện (**Chương 4**).

- Một bộ kết quả đánh giá chất lượng câu trả lời được sinh và ngữ cảnh truy xuất, tham khảo bốn chỉ số RAGAs gồm độ trung thực với ngữ cảnh, độ liên quan của câu trả lời, độ chính xác ngữ cảnh và độ thu hồi ngữ cảnh, trên cấu hình truy xuất tốt nhất (**Chương 4**).

1.6 Cấu trúc khóa luận

Cấu trúc của khóa luận được chia làm 5 chương như sau:

- **Chương 1: TỔNG QUAN ĐỀ TÀI**
Trình bày lý do chọn đề tài, các công trình liên quan, mục tiêu, phạm vi và những điểm mới của khóa luận.
- **Chương 2: CƠ SỞ LÝ THUYẾT**
Trình bày các khái niệm và cơ sở lý thuyết nền tảng cần thiết để thực hiện khóa luận.
- **Chương 3: PHƯƠNG PHÁP THỰC HIỆN**
Trình bày chi tiết kiến trúc và cách hoạt động của hệ thống đã hiện thực.
- **Chương 4: THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN**
Trình bày phương pháp thực nghiệm, kết quả đánh giá truy xuất, phân tích, thảo luận và trạng thái của các thí nghiệm.
- **Chương 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN**
Đưa ra kết luận về đề tài và đề xuất các hướng phát triển trong tương lai.

Chương 2

CƠ SỞ LÝ THUYẾT

Tóm tắt chương

Chương này trình bày các kiến thức nền tảng cần thiết cho khóa luận. Các nội dung được trình bày theo thứ tự: đặc điểm của học liệu đa định dạng; các mô hình ngôn ngữ và mô hình biểu diễn được sử dụng; khung sinh tăng cường truy xuất (Retrieval-augmented generation - RAG) và phần mở rộng đa phương thức của nó; các kỹ thuật truy xuất thông tin; các kỹ thuật xử lý học liệu; nguyên tắc sinh câu trả lời có căn cứ; và các chỉ số cùng phương pháp thống kê dùng để đánh giá.

2.1 Học liệu đa định dạng và siêu dữ liệu học liệu

Trong khóa luận này, học liệu đa định dạng là tập các tài nguyên phục vụ một môn học ở nhiều dạng khác nhau, gồm video bài giảng, slide, giáo trình và tài liệu ở dạng PDF hoặc Word, và tài liệu bài tập. Mỗi định dạng có cách định vị nội dung riêng: số trang với tệp PDF và DOCX, số slide với tệp PPTX, mốc thời gian (timestamp) với video. Vì một mục tiêu của trợ lý ảo là để người học kiểm chứng câu trả lời với học liệu gốc, hệ thống phải giữ lại các thông tin định vị này cùng với nội dung.

Siêu dữ liệu (metadata) là dữ liệu mô tả một tài nguyên, chẳng hạn tài nguyên đó thuộc môn học nào hay nội dung nằm ở trang nào. Đối với học liệu, IEEE đã ban hành tiêu chuẩn IEEE Std 1484.12.1-2020 về siêu dữ liệu đối tượng học tập (Learning object metadata - LOM), hiện được ghi nhận là tiêu chuẩn còn hiệu lực [16]. Khóa luận không cài đặt tiêu chuẩn này mà chỉ dùng một tập nhỏ các trường siêu dữ liệu phục vụ truy xuất và trích dẫn (**Mục 3.2**); việc mở rộng theo hướng của LOM là một hướng phát triển (**Chương 5**).

2.2 Mô hình ngôn ngữ lớn và mô hình biểu diễn vector

Khóa luận dùng họ mô hình Qwen3 cho cả việc sinh văn bản và việc chuyển văn bản, ảnh thành vector. Báo cáo kỹ thuật của Qwen3 nêu rằng họ mô hình này mở rộng khả năng hỗ trợ đa ngôn ngữ từ 29 lên 119 ngôn ngữ và phương ngữ [32].

Biểu diễn vector (embedding) là phép ánh xạ một đoạn văn bản, một ảnh hoặc một cặp văn bản và ảnh thành một vector số thực, sao cho các đối tượng có nội dung gần nhau thì có vector gần nhau. Qwen3 Embedding là một chuỗi mô hình biểu diễn văn bản và xếp hạng lại xây dựng trên nền Qwen3, được huấn luyện qua nhiều giai đoạn kết hợp tiền huấn luyện không giám sát quy mô lớn với tinh chỉnh có giám sát [34]. Qwen3-VL-Embedding được xây dựng trên nền Qwen3-VL, ánh xạ văn bản, ảnh, ảnh tài liệu và video vào một không gian biểu diễn thống nhất và hỗ trợ hơn 30 ngôn ngữ [21]. Qwen3-VL là một mô hình ngôn ngữ thị giác (Vision-language model - VLM) của họ Qwen3, tiếp nhận văn bản, ảnh và video trong cùng một ngữ cảnh xen kẽ [3]. Trong hệ thống của chúng tôi, mô hình biểu diễn văn bản và mô hình biểu diễn thị giác cho hai không gian vector khác nhau, vì vậy vector của hai loại không được so sánh trực tiếp và được lưu ở hai tập vector (collection) riêng (Mục 3.2).

2.3 Sinh tăng cường truy xuất

2.3.1 Sinh tăng cường truy xuất

Các mô hình ngôn ngữ lớn (Large Language Model - LLM) lưu tri thức trong tham số của mình, nhưng khả năng truy cập và thao tác chính xác tri thức đó còn hạn chế trên các tác vụ cần nhiều tri thức [20]. Ngoài ra, LLM còn gặp các vấn đề như sinh nội dung sai lệch, kiến thức lỗi thời và quá trình suy luận thiếu minh bạch, không truy vết được [13]. RAG được đề xuất để khắc phục bằng cách bổ sung tri thức lấy từ một kho ngoài [20, 13]. Một hệ thống RAG gồm hai mô-đun: mô-đun truy xuất tìm các đoạn liên quan trong kho ngoài, và mô-đun sinh dùng một LLM tạo câu trả lời dựa trên câu hỏi cùng các đoạn đã truy xuất [8].

2.3.2 Mở rộng đa phương thức

RAG đa phương thức mở rộng kho tri thức từ văn bản sang ảnh, video và các tài liệu trực quan. MuRAG là một trong những công trình truy xuất và sinh câu trả lời

cho bài toán hỏi đáp mở trên ảnh và văn bản [4]; một khảo sát hệ thống hóa các bộ dữ liệu, thước đo và phương pháp truy xuất, hợp nhất, bổ sung ngữ cảnh và sinh của hướng này [1], và một khảo sát khác phân loại các phương pháp cho bài toán hiểu tài liệu theo lĩnh vực, phương thức truy xuất và mức độ chi tiết [12].

Đối với tài liệu có bố cục, có hai cách tiếp cận chính. Cách thứ nhất trích xuất văn bản từ tài liệu rồi xử lý như văn bản thuần; tài liệu truyền đạt thông tin không chỉ bằng chữ mà còn bằng hình, bố cục, bảng và cả phông chữ, và các hệ thống truy xuất chủ yếu dựa vào văn bản trích xuất khó khai thác hiệu quả từ các nguồn đó [9]. Cách thứ hai biểu diễn trực tiếp ảnh trang của tài liệu bằng VLM và truy xuất trên ảnh đó [9, 33, 30]. Hệ thống của chúng tôi giữ cả hai nhánh: văn bản trích xuất (cùng văn bản nhận dạng từ ảnh) và ảnh (ảnh trang hiện chỉ có với tệp PDF), mỗi nhánh ở một không gian vector riêng (**Chương 3**).

2.4 Truy xuất thông tin

2.4.1 Truy xuất dày

Truy xuất dày (dense retrieval) biểu diễn cả câu hỏi và các đoạn văn bằng vector, rồi tìm các đoạn có vector gần vector câu hỏi nhất; các vector có thể được học từ một số ít cặp câu hỏi và đoạn văn bằng một khung gồm hai bộ mã hóa đơn giản [18]. Độ gần giữa hai vector được đo bằng độ tương đồng cosine, cách chuẩn để định lượng sự giống nhau của hai tài liệu từ biểu diễn vector của chúng [24]:

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (2.1)$$

Khi các vector đã được chuẩn hóa về độ dài 1 thì độ tương đồng cosine bằng tích vô hướng. Tìm kiếm chính xác trên số lượng lớn vector rất tốn kém nên thường dùng chỉ mục cho tìm kiếm lân cận xấp xỉ gần nhất (Approximate Nearest Neighbor - ANN). HNSW (Hierarchical Navigable Small World) là thuật toán lập chỉ mục và tìm kiếm ANN cực kỳ hiệu quả trên dữ liệu vector, dựa hoàn toàn trên đồ thị, xây dựng từ các đồ thị tiểu thế giới có thể điều hướng với cấu trúc phân cấp [23].

2.4.2 Truy xuất thưa và BM25

Truy xuất thưa (sparse retrieval) dựa trên sự khớp từ vựng giữa câu hỏi và tài liệu; các mô hình không gian vector thưa truyền thống như TF-IDF hay BM25 từng là phương pháp mặc định cho truy xuất đoạn văn [18]. BM25 thuộc khung xác suất

liên quan [27]. Dạng thường gặp của điểm BM25 giữa tài liệu D và câu hỏi Q là

$$\text{BM25}(D, Q) = \sum_{t \in Q} \text{IDF}(t) \cdot \frac{f(t, D)(k_1 + 1)}{f(t, D) + k_1(1 - b + b|D|/\overline{|D|})} \quad (2.2)$$

trong đó $f(t, D)$ là số lần từ t xuất hiện trong D , $|D|$ là độ dài của D , $\overline{|D|}$ là độ dài trung bình của các tài liệu, còn k_1 và b là các tham số. Cách tính $\text{IDF}(t)$ cụ thể phụ thuộc vào cài đặt. Hệ thống của chúng tôi dùng lớp `BM25Okapi` của gói `rank-bm25` với các tham số mặc định của gói.

Do việc chọn từ của con người biến thiên rất lớn [10], khớp từ vựng thuần túy có thể bỏ sót tài liệu dùng thuật ngữ khác với câu hỏi. Nhận định này là một cơ sở để chúng tôi kết hợp truy xuất thưa với truy xuất dày trong hệ thống.

2.4.3 Hợp nhất thứ hạng nghịch đảo

Hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF) là một phương pháp không giám sát để kết hợp các danh sách xếp hạng do nhiều phương pháp truy xuất tạo ra; các tác giả báo cáo RRF cho kết quả tốt hơn từng hệ thống riêng lẻ và tốt hơn phương pháp Condorcet Fuse [5]. Điểm của một tài liệu d là tổng nghịch đảo thứ hạng của nó trong các danh sách chứa nó:

$$\text{RRF}(d) = \sum_{g \in G} \frac{1}{k + \text{rank}_g(d)} \quad (2.3)$$

với G là tập các danh sách xếp hạng và k là một hằng số. Vì công thức chỉ dùng thứ hạng, RRF không cần chuẩn hóa điểm giữa các thang khác nhau, chẳng hạn điểm cosine và điểm BM25. Đổi lại, công thức coi mọi danh sách có vai trò như nhau và không xét độ tin cậy của từng nguồn.

2.4.4 Bộ xếp hạng lại

Bộ xếp hạng lại (reranker) chấm lại các ứng viên đã truy xuất bằng một mô hình xem xét đồng thời câu hỏi và từng đoạn văn; ví dụ mô hình BERT đã được dùng theo cách này để xếp hạng lại đoạn văn theo câu hỏi [25]. Qwen3-Reranker thuộc chuỗi Qwen3 Embedding [34] và, theo thể mô hình, chấm điểm dựa trên xác suất mô hình trả lời “có” hay “không” cho việc đoạn văn đáp ứng yêu cầu của câu hỏi.

2.4.5 Truy vấn mở rộng bằng tài liệu giả định

HyDE (Hypothetical Document Embeddings) [11] yêu cầu một mô hình ngôn ngữ làm theo chỉ dẫn sinh ra một tài liệu giả định trả lời câu hỏi, sau đó dùng một bộ

mã hóa để biểu diễn tài liệu này thành vector và tìm các tài liệu thật có vector gần nó. Tài liệu giả định có thể chứa chi tiết sai, nhưng nút thắt dây của bộ mã hóa lọc bỏ các chi tiết đó và neo tài liệu giả định vào nội dung thật của kho tài liệu thông qua các vector biểu diễn [11]. Trong hệ thống của chúng tôi, HyDE là tùy chọn và mặc định tắt (Mục 3.6).

2.5 Xử lý học liệu đa định dạng

2.5.1 Phân tích bố cục tài liệu

Docling là gói mã nguồn mở chuyển đổi tài liệu PDF, dựa trên các mô hình phân tích bố cục (DocLayNet) và nhận dạng cấu trúc bảng (TableFormer) [2]; trong mã nguồn của hệ thống, bộ chuyển đổi này cũng được dùng cho tệp DOCX và PPTX. Trong hệ thống của chúng tôi, kết quả phân tích được dùng để tách văn bản, bảng và hình dựa trên nhãn loại của từng phần tử và ghi lại số trang mà công cụ cung cấp (Mục 3.3).

2.5.2 Nhận dạng ký tự quang học

OCR chuyển ảnh có chứa chữ thành văn bản. Tesseract là một công cụ OCR mã nguồn mở; bài mô tả của Smith nhấn mạnh việc tìm dòng chữ, các đặc trưng và phương pháp phân loại, cùng bộ phân loại thích nghi của công cụ này [28].

2.5.3 Nhận dạng giọng nói tự động

ASR chuyển âm thanh thành văn bản. Whisper được huấn luyện để dự đoán bản phiên âm từ một lượng lớn âm thanh trên Internet; khi mở rộng đến 680 000 giờ giám sát đa ngôn ngữ và đa tác vụ, các mô hình thu được tổng quát hóa tốt trên các bộ đánh giá chuẩn (benchmark) theo cách chuyển giao không mẫu, không cần tinh chỉnh [26]. Trong khóa luận, bản phiên âm là văn bản kèm mốc thời gian của từng đoạn lời nói, thu được từ một hệ thống ASR hoặc từ một tệp đi kèm (sidecar) do người dùng cung cấp.

2.5.4 Băm ảnh

Băm trung bình (average hash) là một kỹ thuật đơn giản để so sánh hai ảnh: ảnh được chuyển sang thang xám, thu nhỏ về một lưới nhỏ, mỗi điểm ảnh được so với giá trị trung bình của lưới để tạo một bit, và mức giống nhau của hai ảnh được đo

bằng số bit khác nhau giữa hai mã băm (khoảng cách Hamming). Hệ thống dùng kỹ thuật này để loại các khung hình video gần trùng nhau (**Mục 3.4**).

2.5.5 Phân đoạn văn bản

Phân đoạn văn bản (chunking) là việc chia văn bản dài thành các đoạn ngắn, có thể chồng lấp lên nhau, để mỗi đoạn được biểu diễn thành vector và lập chỉ mục riêng. Chi tiết cách phân đoạn của hệ thống được nêu ở **Mục 3.3**.

2.6 Sinh câu trả lời có căn cứ

Trong khóa luận, một câu trả lời có căn cứ là câu trả lời chỉ dựa trên các đoạn đã được truy xuất và kèm trích dẫn tới nguồn (tệp, số trang, mốc thời gian) để người học kiểm chứng. RAG được xem là hướng giảm hiện tượng sinh nội dung sai lệch và quá trình suy luận không truy vết được [13]. Để hiện thực nguyên tắc này, hệ thống dùng hai cơ chế: câu lệnh (prompt) dẫn dắt mô hình chỉ dựa vào ngữ cảnh và nguồn được cung cấp, và việc đưa ảnh trang vào một VLM khi văn bản trích xuất có thể đã làm mất thông tin về bố cục hay hình minh họa [33, 3]. Chi tiết được trình bày ở **Mục 3.7**.

2.7 Đánh giá hệ thống truy xuất và sinh

2.7.1 Các chỉ số truy xuất

Độ chính xác (Precision) là tỉ lệ giữa số tài liệu liên quan được truy xuất và tổng số tài liệu được truy xuất; độ phủ (Recall) là tỉ lệ giữa số tài liệu liên quan được truy xuất và tổng số tài liệu liên quan; và điểm F1 là trung bình điều hòa của hai đại lượng đó [24]. Nếu tp , fp , fn lần lượt là số kết quả đúng được trả về, số kết quả sai được trả về và số kết quả đúng bị bỏ sót

$$Precision = \frac{tp}{tp + fp}, \quad Recall = \frac{tp}{tp + fn}, \quad F_1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall}. \quad (2.4)$$

Với kết quả có xếp hạng, các đại lượng được tính trên K kết quả đầu tiên và ký hiệu là $Precision@K$, $Recall@K$ và $F1@K$; cách tính cụ thể trong khóa luận được nêu ở **Mục 3.8**. Điểm của một hệ thống là trung bình macro, tức trung bình cộng của điểm trên từng câu hỏi.

2.7.2 Đánh giá hệ thống sinh tăng cường truy xuất

RAGAs là một khung đánh giá các hệ thống RAG, đề xuất các chỉ số cho khả năng truy xuất, khả năng khai thác ngữ cảnh một cách trung thực của LLM và chất lượng của phần sinh [8]. Trong khóa luận, RAGAs được sử dụng làm khung đánh giá phần sinh câu trả lời và ngữ cảnh truy xuất. Cụ thể, mã nguồn gọi các chỉ số Faithfulness, ResponseRelevancy, LLMContextPrecisionWithReference và LLMContextRecall; trong luận văn, các chỉ số này lần lượt được gọi là độ trung thực với ngữ cảnh (faithfulness), độ liên quan của câu trả lời (answer relevance), độ chính xác ngữ cảnh (context precision) và độ thu hồi ngữ cảnh (context recall). Việc chấm điểm sử dụng câu hỏi, ngữ cảnh truy xuất, câu trả lời sinh ra và thông tin chuẩn tương ứng của bộ đánh giá. Các chỉ số Precision, Recall và F1 của khâu truy xuất được tính riêng theo quy tắc đối chiếu bằng chứng trình bày ở **Mục 3.8**.

2.7.3 Khoảng tin cậy bằng phương pháp lấy mẫu lại

Phương pháp lấy mẫu lại (bootstrap) ước lượng độ bất định của một thống kê bằng cách lấy mẫu có hoàn lại từ chính dữ liệu quan sát [7]; một nghiên cứu đã so sánh lấy mẫu lại với các kiểm định khác cho đánh giá truy xuất thông tin [29]. Trong khóa luận, chúng tôi dùng lấy mẫu lại ghép cặp với khoảng phân vị: lấy mẫu có hoàn lại các đơn vị độc lập (từng câu hỏi, hoặc từng cụm câu hỏi có cùng nội dung truy vấn khi câu hỏi bị lặp lại), với mỗi mẫu tính hiệu số trung bình của một chỉ số giữa hai hệ thống, rồi lấy phân vị 2,5% và 97,5% của các hiệu số đó làm khoảng tin cậy 95%. Nếu khoảng này không chứa 0 thì hiệu số được coi là khác 0 ở mức tin cậy đó (**Mục 4.5**).

Chương 3

PHƯƠNG PHÁP THỰC HIỆN

Tóm tắt chương

Trong chương này, chúng tôi trình bày kiến trúc và cách hoạt động của hệ thống trợ lý ảo đã được hiện thực. Nội dung gồm: kiến trúc tổng thể, biểu diễn đối tượng tri thức và siêu dữ liệu, các bước tiền xử lý học liệu dạng tài liệu và dạng video, lập chỉ mục trên hai không gian vector, thuật toán truy xuất lai (hybrid retrieval) đa phương thức, cách sinh câu trả lời có căn cứ, khung đánh giá truy xuất không rò rỉ dữ liệu và các hạn chế của thiết kế hiện tại. Mọi mô tả trong chương đều được đối chiếu trực tiếp với mã nguồn của hệ thống; các tham số nêu trong chương là giá trị mặc định của mã nguồn, trừ khi có ghi chú khác.


3.1 Kiến trúc tổng thể

Hệ thống được tổ chức thành các khối chức năng tách rời: nạp và tiền xử lý học liệu, lập chỉ mục, truy xuất, sinh câu trả lời và đánh giá. Các khối được lắp ghép trong hàm `build_services` (tệp `app/factory.py`), hàm này tạo ra một đối tượng gồm kho vector, kho lưu tệp trung gian, sổ đăng ký các tệp đã lập chỉ mục, hai dịch vụ biểu diễn vector (embedding), luồng nạp dữ liệu, bộ truy xuất và dịch vụ sinh câu trả lời. Các mô hình được nạp vào bộ nhớ theo nhu cầu: mô hình sinh văn bản chỉ được nạp ở lần hỏi đầu tiên, còn các lệnh nạp dữ liệu, tìm kiếm và thống kê không nạp mô hình này.

Học liệu gốc được giữ nguyên tại chỗ. Kho vector ChromaDB¹ chỉ lưu vector, văn bản và siêu dữ liệu vị trí; các tệp nhị phân phát sinh trong quá trình xử lý (ảnh trang, ảnh hình, khung hình video, âm thanh trích xuất) được lưu trong

¹ChromaDB: <https://github.com/chroma-core/chroma>

một thư mục riêng dưới quyền quản lý của hệ thống. Hệ thống có hai điểm truy cập: giao diện dòng lệnh (Command-line interface - CLI) với các lệnh chính là ingest, search, ask, stats, eval, prepare-retrieval-queries, prepare-golden-from-draft, benchmark-retrieve và score-retrieval; và API xây dựng bằng FastAPI (Mục 3.7.4). Hình 3.1 mô tả luồng dữ liệu tổng quát.



Hình 3.1: Kiến trúc tổng thể của hệ thống trợ lý ảo

3.2 Biểu diễn đối tượng tri thức và siêu dữ liệu

Mỗi đơn vị tri thức trong hệ thống là một vector cùng văn bản kèm theo và một tập siêu dữ liệu. Đơn vị tri thức có thể là một đoạn văn bản của tài liệu, một bảng, một ảnh hoặc ảnh chụp một trang, một cửa sổ phiên âm của video hoặc một khung hình được chọn của video. Bảng 3.1 liệt kê các trường siêu dữ liệu mà hệ thống ghi cho từng đối tượng; các trường không có giá trị được bỏ qua, và mọi giá trị được đưa về kiểu nguyên thủy (chuỗi, số nguyên, số thực, logic) vì ChromaDB không chấp nhận danh sách hay đối tượng lồng nhau.

Mã định danh của mỗi vector có dạng `{document_id}:{loại}:{chunk_index}`, trong đó `document_id` là mã băm SHA-256 của nội dung tệp nên hai bản sao giống

Bảng 3.1: Các trường siêu dữ liệu được ghi cho từng đối tượng tri thức

Trường	Ý nghĩa	Áp dụng cho
document_id	Mã băm SHA-256 của nội dung tệp gốc	Mọi đối tượng
relative_path, filename, file_type	Đường dẫn tương đối so với thư mục dự án, tên tệp và loại tệp (với video, loại tệp luôn được ghi là mp4)	Mọi đối tượng
source, file_name	Đường dẫn tuyệt đối của tệp gốc và tên tệp (chuẩn hóa NFC)	Mọi đối tượng
content_type	Một trong text, table, page, image, video_segment, video_frame	Mọi đối tượng
chunk_index	Chỉ số của đối tượng, đánh riêng theo từng loại: số thứ tự đoạn văn bản, số thứ tự bảng, số trang (ảnh trang), số thứ tự ảnh, số thứ tự cửa sổ (cửa sổ phiên âm), thời điểm tính bằng mili giây (khung hình video, cộng thêm 1 nếu trùng); văn bản nhận dạng từ ảnh dùng chỉ số từ 10 000	Mọi đối tượng
course	Môn học, suy ra từ thư mục con đầu tiên dưới assets/	Mọi đối tượng có đường dẫn dưới assets/
page_number	Số trang (hoặc số slide)	Văn bản, bảng, ảnh của tài liệu
section	Tiêu đề mục gần nhất	Chỉ đoạn văn bản
image_path	Đường dẫn ảnh đã lưu	Ảnh, ảnh trang, khung hình
caption	Chú thích ảnh do Docling cung cấp, nếu có; được lưu cùng siêu dữ liệu ảnh	Mọi ảnh tài liệu
video_id, start_time, end_time	Mã video, thời điểm bắt đầu và kết thúc của cửa sổ (giây)	Cửa sổ phiên âm, khung hình
segment_id, timestamp	Mã của cửa sổ chứa khung hình và thời điểm của khung hình (giây)	Chỉ khung hình

hệ nhau tự động trùng mã. Đường dẫn tương đối được ghi với dấu phân cách /; tên tệp và các khóa của cửa sổ đăng ký được chuẩn hóa về dạng Unicode NFC, và việc chuẩn hóa NFC được áp dụng lại khi so khớp đường dẫn ở bước truy xuất và đánh giá, để tránh sai khác khi tên tệp tiếng Việt được lưu ở các dạng mã hóa khác nhau. Hai loại vector được lưu ở hai tập vector riêng của ChromaDB vì chúng thuộc hai không gian biểu diễn khác nhau (**Mục 3.5**): tập vector text_embeddings chứa đoạn văn bản, bảng, văn bản nhận dạng được từ ảnh và cửa sổ phiên âm của video; tập vector visual_embeddings chứa ảnh, ảnh trang và khung hình video. Cả hai tập vector đều dùng khoảng cách cosine, và điểm của một kết quả được tính là $1 - d$ với d là khoảng cách do ChromaDB trả về.

Trường course là thông tin duy nhất về cấu trúc khóa học mà hệ thống hiện ghi

lại. Các thông tin khác như chương, tuần học, mục tiêu học tập, độ khó hay quyền truy cập chưa được biểu diễn trong lược đồ; chúng tôi ghi nhận đây là một hạn chế (**Mục 3.9**).

3.3 Tiền xử lý học liệu dạng tài liệu, bảng và ảnh

3.3.1 Phân tích tài liệu

Với tệp PDF, DOCX và PPTX, hệ thống dùng Docling² [2]. Báo cáo kỹ thuật của công cụ này mô tả việc chuyển đổi tài liệu PDF dựa trên các mô hình phân tích bố cục và nhận dạng cấu trúc bảng [2]. Trong mã nguồn, bộ chuyển đổi được cấu hình cho PDF với việc nhận dạng ký tự tắt (`do_ocr=False`), nhận dạng cấu trúc bảng bật, và yêu cầu sinh ảnh trang cùng ảnh của các hình với tỉ lệ 1,0. Hệ thống duyệt các phần tử theo thứ tự xuất hiện trong tài liệu và xử lý như sau:

- Phần tử có nhãn tiêu đề hoặc tiêu đề mục được ghi nhận thành khối văn bản và trở thành giá trị `section` của các khối văn bản đứng sau nó.
- Đầu trang, chân trang, chú thích chân trang, hình và bảng không được đưa vào luồng văn bản.
- Mỗi bảng được xuất sang dạng markdown và lưu thành một đối tượng riêng (`content_type=table`); bảng không bị chia nhỏ.
- Mỗi hình được lưu thành tệp PNG và trở thành một đối tượng ảnh. Mã nguồn có đọc chú thích của hình, nhưng do đọc sai tên thuộc tính của Docling nên chú thích không được ghi (**Mục 3.9**); văn bản chú thích vẫn có thể xuất hiện như một đoạn văn bản thường vì nhãn chú thích không bị bỏ qua.

3.3.2 Nhận dạng ký tự dự phòng

Việc OCR chỉ được dùng khi cần. Nếu không trang nào của một tài liệu có từ 40 ký tự văn bản gốc trở lên (ví dụ tài liệu quét) và có ảnh trang (trên thực tế chỉ xảy ra với tệp PDF, xem trên), hệ thống chạy Tesseract³ [28] trên từng ảnh trang và bổ sung văn bản nhận dạng được vào tài liệu. Tệp ảnh độc lập cũng được nhận dạng ký tự khi nạp. Văn bản nhận dạng được từ ảnh được lập chỉ mục thành các đối tượng văn bản riêng với `chunk_index` bắt đầu từ 10 000 để không trùng với các đoạn văn bản thường, do đó chúng cũng tham gia vào truy xuất thưa (`sparse retrieval`) (**Mục 3.5**).

²Docling: <https://github.com/docling-project/docling>

³Tesseract: <https://github.com/tesseract-ocr/tesseract>

3.3.3 Phân đoạn văn bản

Phân đoạn văn bản (chunking) được thực hiện bằng bộ chia đệ quy theo ký tự của LangChain (`RecursiveCharacterTextSplitter`); đơn vị của kích thước đoạn và độ chồng lấp là ký tự, không phải đơn vị văn bản (token). **Bảng 3.2** liệt kê kích thước theo loại tệp. Khối văn bản ngắn hơn kích thước đoạn được giữ nguyên; các đoạn kế thừa `page_number` và `section` của khối gốc, và `chunk_index` tăng liên tục trong toàn tệp.

Bảng 3.2: Kích thước đoạn và độ chồng lấp theo loại tệp (đơn vị: ký tự)

Loại tệp	Kích thước đoạn	Độ chồng lấp
PDF, DOCX	350	60
PPTX	280	40
TXT, Markdown	500	50
Loại khác (giá trị mặc định)	500	50

3.3.4 Loại trùng và cập nhật tăng dần


Trước khi xử lý, hệ thống tính mã băm SHA-256 của nội dung từng tệp và tra trong sổ đăng ký (tệp `data/index_manifest.json`, gồm hai ánh xạ: từ mã băm sang thông tin tệp và từ đường dẫn sang mã băm). Tệp có nội dung không đổi và đã có vector thì được bỏ qua. Nếu một đường dẫn xuất hiện với nội dung mới, hệ thống xóa vector và các tệp trung gian của phiên bản cũ rồi lập chỉ mục lại. Hồ sơ kích thước đoạn hiện hành được ghi cùng mỗi tài liệu, nên khi các kích thước trong **Bảng 3.2** thay đổi (hoặc khi người dùng yêu cầu), tài liệu được lập chỉ mục lại mà không cần xóa thủ công. Sau mỗi lần nạp có thay đổi, chỉ mục từ vựng BM25 được dựng lại từ tập vector văn bản mà không cần biểu diễn vector lại.

3.4 Tiền xử lý video bài giảng

Video được xử lý qua bảy bước như **Hình 3.2**. Mục tiêu là biến một video dài thành các cửa sổ 30 giây, mỗi cửa sổ có văn bản phiên âm và một vài khung hình đại diện, cùng thông tin thời điểm để trích dẫn.

Bước 1 và 2: siêu dữ liệu và âm thanh. Thời lượng, độ phân giải, tốc độ khung hình và việc có âm thanh hay không được đọc bằng công cụ `ffprobe` của FFmpeg⁴.

⁴FFmpeg: <https://ffmpeg.org>



Hình 3.2: Luồng xử lý video bài giảng

Âm thanh được tách bằng FFmpeg sang định dạng PCM 16 bit, tần số 16 kHz, một kênh.

Bước 3: phiên âm. Hệ thống ưu tiên dùng tệp đi kèm (sidecar) chứa mốc thời gian nếu nó nằm cạnh video, có tên `[tên video]_segments.json` hoặc `[tên video].segments.json` và chứa danh sách các đoạn gồm thời điểm bắt đầu, thời điểm kết thúc và văn bản. Nếu không có tệp này, hệ thống phiên âm bằng faster-whisper⁵, một bản cài đặt lại của Whisper [26] trên bộ suy luận CTranslate2, với mô hình base, chạy trên bộ xử lý trung tâm (Central processing unit - CPU) ở độ chính xác số nguyên 8 bit, và ép ngôn ngữ là tiếng Việt theo mặc định. Kết quả phiên âm được lưu để dùng lại khi tiến trình bị gián đoạn.

Cửa sổ thời gian. Video được chia thành các cửa sổ liên tiếp dài 30 giây (cửa sổ cuối có thể ngắn hơn). Mỗi đoạn phiên âm được gán nguyên vẹn cho cửa sổ chứa thời điểm bắt đầu của nó và không bị cắt giữa câu, nên văn bản của một cửa sổ có thể kéo dài quá thời điểm kết thúc cửa sổ đôi chút.

Bước 4: khung hình thô. FFmpeg lấy mẫu một khung hình mỗi 10 giây và lưu thành ảnh JPEG.

⁵faster-whisper: <https://github.com/SYSTRAN/faster-whisper>

Bước 5: chọn khung hình đại diện. Với mỗi khung hình thô, hệ thống tính băm trung bình (average hash) 8×8 : ảnh được chuyển sang thang xám, thu nhỏ còn 8×8 điểm ảnh, mỗi điểm ảnh được so với giá trị trung bình để tạo một bit, cho ra một số 64 bit. Độ tương đồng của hai khung hình a và b là

$$\text{sim}(a, b) = 1 - \frac{H(h_a, h_b)}{64} \quad (3.1)$$

trong đó H là khoảng cách Hamming giữa hai mã băm. Trong mỗi cửa sổ, khung hình có $\text{sim} \geq 0,90$ so với khung hình gần nhất đã được giữ lại (tức khác nhau tối đa 6 trong 64 bit) bị coi là gần trùng và bị loại bỏ. Nhận dạng ký tự bằng Tesseract được chạy trên các khung hình cách nhau ít nhất 30 giây; nhận dạng biên cảnh bằng PySceneDetect là tùy chọn và mặc định tắt. Với các khung hình còn lại, hệ thống chọn tối đa $M = 3$ khung hình cho mỗi cửa sổ bằng cách chọn tham lam theo điểm

$$s(c) = 0,35 v(c) + 0,30 o(c) + 0,20 b(c) + 0,15 t(c) \quad (3.2)$$

trong đó $v(c) = 1 - \text{sim}$ giữa khung hình c và khung hình đứng trước nó sau khi loại trùng ($v = 1$ với khung hình đầu tiên); $o(c) \in \{0, 1\}$ bằng 1 nếu văn bản nhận dạng được của c (sau khi chuẩn hóa khoảng trắng và chữ thường) khác văn bản không rỗng gần nhất trước đó, và bằng 0 nếu cả hai đều rỗng; $b(c) \in \{0, 1\}$ bằng 1 nếu c nằm ở biên cảnh; và $t(c) = \min(1, \delta(c) / (D/M))$ đo độ phủ thời gian, với $\delta(c)$ là khoảng cách đến khung hình đã chọn gần nhất, D là độ dài cửa sổ ($t = 1$ khi chưa chọn khung hình nào). Bốn trọng số 0,35, 0,30, 0,20 và 0,15 là giá trị mặc định của mã nguồn. Với tham số mặc định (khung hình thô cách nhau 10 giây, cửa sổ 30 giây, $M = 3$), mỗi cửa sổ có tối đa 3 khung hình ứng viên, nên sau khi loại trùng quy trình giữ lại tất cả các ứng viên còn lại: khi đó điểm chỉ ảnh hưởng đến thứ tự chọn (kết quả cuối cùng được sắp lại theo thời gian) và bước loại trùng bằng băm trung bình là bộ lọc duy nhất thực sự thay đổi tập khung hình được giữ. Điểm chọn chỉ có tác dụng khi thay đổi các tham số này.

Bước 6 và 7: lập chỉ mục. Văn bản của mỗi cửa sổ có phiên âm được lập chỉ mục thành một đối tượng `video_segment` mang `start_time` và `end_time`. Mỗi khung hình được chọn được lập chỉ mục thành một đối tượng `video_frame` mang `timestamp`; văn bản đi kèm là văn bản nhận dạng được của khung hình đó, hoặc phiên âm của cửa sổ nếu khung hình không có văn bản nhận dạng, và khi có văn bản thì đầu vào của mô hình biểu diễn là cặp gồm văn bản và ảnh. Cửa sổ không có phiên âm không tạo đối tượng văn bản nhưng khung hình của nó vẫn được lập chỉ mục.

Điểm lưu trạng thái (checkpoint). Tiến trình xử lý một video có thể kéo dài nhiều giờ, nên hệ thống ghi lại các giai đoạn đã hoàn thành (siêu dữ liệu, âm thanh, phiên

âm, khung hình thô, khung hình đã chọn, đã lập chỉ mục) vào một tệp điểm lưu trạng thái cùng số hiệu phiên bản của luồng xử lý (pipeline), hiện là v2-long. Điểm lưu chỉ được dùng lại khi mã video, phiên bản và thời lượng đã xử lý (sai lệch không quá 1 giây) đều khớp, và giai đoạn không bao giờ bị lùi lại khi một bước được chạy lại. Một video chỉ bị bỏ qua khi thời lượng đã xử lý bao phủ thời lượng cần xử lý; nhờ vậy một lần chạy thử với giới hạn thời lượng không làm hệ thống bỏ qua video ở lần chạy đầy đủ sau đó.

3.5 Biểu diễn vector và lập chỉ mục

Hệ thống dùng hai mô hình biểu diễn vector khác nhau, tương ứng với hai không gian vector. **Bảng 3.3** tóm tắt các mô hình của họ Qwen3 mà hệ thống sử dụng cùng các thông số nêu trong thẻ mô hình tương ứng trên Hugging Face.

Bảng 3.3: Các mô hình của họ Qwen3 được hệ thống sử dụng

Mô hình	Vai trò	Thông số theo thẻ mô hình
Qwen3-Embedding-0.6B [34]	Biểu diễn vector của văn bản và của truy vấn văn bản	0,6 tỷ tham số; ngữ cảnh 32 nghìn đơn vị văn bản; tối đa 1024 chiều; hơn 100 ngôn ngữ; hỗ trợ chỉ dẫn theo tác vụ
Qwen3-VL-Embedding-2B [21]	Biểu diễn vector của ảnh, ảnh trang, khung hình và của truy vấn văn bản trên không gian thị giác	2 tỷ tham số; ngữ cảnh 32 nghìn đơn vị văn bản; tối đa 2048 chiều; nhận văn bản, ảnh, ảnh chụp màn hình và video; hơn 30 ngôn ngữ
Qwen3-1.7B [32]	Sinh câu trả lời từ văn bản; lập kế hoạch truy vấn	1,7 tỷ tham số (1,4 tỷ không tính lớp nhúng); ngữ cảnh 32 768 đơn vị văn bản; có chế độ suy nghĩ và không suy nghĩ
Qwen3-VL-2B-Instruct [3]	Trả lời dựa trên ảnh trang hoặc ảnh hình được truy xuất	2 tỷ tham số; nhận ảnh, video và văn bản; ngữ cảnh gốc 256 nghìn đơn vị văn bản
Qwen3-Reranker-0.6B [34]	Bộ xếp hạng lại (reranker) tùy chọn (mặc định tắt)	0,6 tỷ tham số; ngữ cảnh 32 nghìn đơn vị văn bản; hơn 100 ngôn ngữ; chấm điểm theo xác suất trả lời có hoặc không

Không gian văn bản. Văn bản tài liệu được biểu diễn bằng Qwen3-Embedding-0.6B qua thư viện langchain-huggingface, với vector được chuẩn hóa độ dài về 1 và lô 8 văn bản. Với truy vấn, hệ thống thêm một chỉ dẫn đứng trước câu hỏi theo dạng Instruct: {tác vụ}\nQuery:{câu hỏi}, trong đó nội dung tác vụ mô tả

rằng đây là câu hỏi của người học về một khóa học và cần tìm học liệu giúp trả lời có bằng chứng; văn bản tài liệu được biểu diễn không kèm chỉ dẫn. Thử mô hình cho biết việc dùng chỉ dẫn thường cải thiện kết quả từ 1% đến 5% ở phần lớn tác vụ hạ nguồn.

Không gian thị giác. Ảnh, ảnh trang và khung hình được biểu diễn bằng Qwen3-VL-Embedding-2B qua thư viện Sentence Transformers với lô một phần tử và vector được chuẩn hóa. Khi ảnh có kèm văn bản (chú thích, văn bản nhận dạng ký tự hoặc phiên âm), đầu vào là cặp văn bản và ảnh; ngược lại đầu vào chỉ là ảnh. Truy vấn văn bản được biểu diễn trong cùng không gian này cùng với chỉ dẫn cố định “truy xuất slide, sơ đồ và khung hình bài giảng phù hợp với truy vấn” (bản tiếng Anh trong mã nguồn).

Chỉ mục vector. ChromaDB được cấu hình với `hnsw:space=cosine`, nghĩa là chỉ mục ANN dùng HNSW [23] với khoảng cách cosine. Các mã vector đã tồn tại được bỏ qua khi thêm, nên việc nạp lại không tạo vector trùng.


Chỉ mục từ vựng. Song song với vector, hệ thống dựng chỉ mục BM25 bằng gói `rank-bm25`⁶ (lớp `BM25Okapi`) trên toàn bộ văn bản của tập vector văn bản thuộc các loại `text`, `table` và `video_segment`. Truy vấn và tài liệu được chuẩn hóa NFC, đưa về chữ thường và tách thành các đơn vị tại mọi chuỗi ký tự không phải chữ, số hoặc dấu gạch dưới; hệ thống không dùng bộ tách từ tiếng Việt. Chỉ mục được lưu thành một tệp `data/bm25.pkl`.

3.6 Truy xuất lai đa phương thức

Bộ truy xuất nhận một câu hỏi, số kết quả cần trả về k , bộ lọc tùy chọn và chờ cho biết có tìm trên không gian thị giác hay không. **Hình 3.3** và **Thuật toán 1** mô tả quy trình; các bước được giải thích dưới đây.

Chuẩn hóa và bộ lọc. Câu hỏi được chuẩn hóa NFC, gộp khoảng trắng và loại ký tự điều khiển. Bộ lọc có thể giới hạn theo tệp, thư mục, môn học (`course`) và loại nội dung (`content_type`); riêng điều kiện lọc theo tệp chỉ được áp dụng cho các danh sách trên vector (qua điều kiện truy vấn của ChromaDB), còn danh sách BM25 chỉ được lọc theo thư mục, môn học và loại nội dung. Số ứng viên lấy về từ mỗi danh sách là $n = \max(k, 20)$ theo mặc định; khi có lọc theo thư mục hoặc môn học, hệ thống lấy nhiều hơn ($5n$ cho tìm trên vector, và $\max(10n, 80)$ cho BM25) rồi lọc sau để còn tối đa n ứng viên. Việc lọc theo môn học có thể thực hiện trực

⁶rank-bm25: <https://pypi.org/project/rank-bm25/>



Hình 3.3: Luồng truy xuất lai đa phương thức

tiếp trong ChromaDB trước khi xếp hạng (tùy chọn `course_prefilter`, mặc định tắt để tương thích với các vector cũ chưa có trường `course`) hoặc bằng lọc sau dựa trên đường dẫn.

Các danh sách ứng viên. Bộ truy xuất tạo ra một hay nhiều danh sách xếp hạng:

- *Truy xuất dày (dense retrieval) trên văn bản:* mỗi biến thể của truy vấn cho một danh sách, xếp theo độ tương đồng cosine trong tập vector văn bản. Biến thể gồm chính câu hỏi; nếu câu hỏi thuộc dạng liệt kê tài liệu hay lộ trình (nhận diện bằng một số cụm từ khóa), hệ thống thêm hai truy vấn con dựng theo luật; và nếu bước lập kế hoạch truy vấn (**Mục 3.7**) được bật thì thêm bản viết lại, các truy vấn con và câu hỏi khái quát của bước đó.
- *Truy xuất thưa:* một danh sách BM25 trên truy vấn đầu tiên, nếu tệp chỉ mục từ vựng tồn tại; nếu thiếu tệp, hệ thống cảnh báo và chỉ dùng truy xuất dày.
- *Truy xuất dày trên ảnh:* một danh sách trong tập vector thị giác, dùng bản viết lại của câu hỏi nếu có; lỗi ở nhánh này chỉ làm mất danh sách đó, không

làm hỏng toàn bộ truy vấn.

- Một danh sách bổ sung từ đoạn văn giả định của HyDE [11] là tùy chọn và mặc định tắt.

Hợp nhất. Các danh sách được kết hợp bằng hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF) [5]: điểm của một đối tượng d là tổng nghịch đảo thứ hạng của nó trong các danh sách chứa nó,

$$\text{RRF}(d) = \sum_{g \in G} \frac{1}{60 + \text{rank}_g(d)} \quad (3.3)$$

trong đó G là tập các danh sách khác rỗng và $\text{rank}_g(d) \geq 1$; hằng số 60 là tham số trong mã nguồn của chúng tôi. Khi có nhiều bản của cùng một đối tượng, bản có độ tương đồng cosine cao nhất được giữ lại làm đại diện. Nếu chỉ có đúng một danh sách khác rỗng thì danh sách đó được giữ nguyên với điểm gốc (cosine hoặc điểm BM25). Hệ thống không gán trọng số riêng cho từng danh sách hay từng loại nội dung.

Thưởng theo loại nội dung. Sau hợp nhất, một bộ xếp hạng lại đơn giản cộng thêm một khoản thưởng cố định vào điểm, theo **Bảng 3.4**. Câu hỏi được coi là hỏi về bài giảng nếu chứa một trong các cụm như “giảng viên”, “buổi”, “video”, “slide”, “bài giảng”, “phút” hoặc từ timestamp (kể cả bản không dấu), hoặc nếu nguồn được chỉ định là tệp video; khi có bước lập kế hoạch truy vấn, phép kiểm tra từ khóa được thực hiện trên bản viết lại của câu hỏi. Bộ xếp hạng lại này luôn hoạt động, kể cả khi bộ xếp hạng lại dựa trên Qwen3-Reranker-0.6B (tùy chọn, mặc định tắt) không được bật. Khi bật, bộ Qwen3-Reranker-0.6B chấm từng cặp (câu hỏi, đoạn văn) bằng xác suất câu trả lời là “có” và xếp lại toàn bộ danh sách chỉ theo xác suất đó, nên thứ tự do khoản thưởng tạo ra bị thay thế; nếu mô hình không nạp được, hệ thống giữ thứ tự cũ và ghi lỗi.

Bảng 3.4: Khoản thưởng cộng vào điểm theo loại nội dung

Loại câu hỏi	Loại nội dung được thưởng	Thưởng
Hỏi về bài giảng	video_segment	+0,02
Hỏi về bài giảng	video_frame	+0,01
Loại khác	text, video_segment	+0,005

Đa dạng theo tệp. Để một tệp không chiếm hết danh sách, mỗi tệp chỉ giữ tối đa 2 kết quả tốt nhất (tham số `retrieve_max_per_file`); các kết quả được lấy xoay vòng giữa các tệp theo thứ tự tệp xuất hiện lần đầu cho đến khi đủ k kết quả.

Mở rộng ngữ cảnh. Kết quả tìm được là đoạn nhỏ nên hệ thống có thể nối thêm ngữ cảnh khi truy vấn mà không cần biểu diễn vector mới. Với đoạn văn bản hoặc bảng có số trang, nội dung được thay bằng phần nối của mọi đoạn cùng tài liệu và cùng trang, sắp theo thứ tự đoạn; mỗi trang chỉ xuất hiện một lần. Với các trường hợp còn lại (đoạn không có số trang và cửa sổ phiên âm), nội dung được thay bằng phần nối của đoạn đứng trước, chính nó và đoạn đứng sau trong cùng tài liệu.

Nén trích xuất. Với nội dung dài từ 240 ký tự, hệ thống tách thành câu và chỉ giữ các câu có ít nhất một từ trùng với từ của câu hỏi (hoặc của các truy vấn viết lại); nếu không câu nào trùng thì giữ nguyên. Việc nén không dùng mô hình ngôn ngữ.

Algorithm 1 Thuật toán truy xuất lai đa phương thức

Input: Câu hỏi q , số kết quả k , bộ lọc F , cờ v (có tìm trên ảnh hay không)

Output: Danh sách R gồm tối đa k kết quả

```

1  $q \leftarrow \text{Normalize}(q)$    $n \leftarrow \max(k, 20)$    $(Q, q_v) \leftarrow \text{QueryVariants}(q)$  //  $Q$ : câu
   hỏi, truy vấn con, bản viết lại;  $q_v$ : bản viết lại nếu có, ngược lại là  $q$ 
2  $G \leftarrow ()$ 
3 foreach  $q_i \in Q$  do
4    $G.append(\text{PostFilter}(\text{DenseSearch}(C_{\text{text}}, \text{Embed}_{\text{text}}(q_i)), F, n))$ 
5 end
6 if BM25 index exists then
7    $G.append(\text{PostFilter}(\text{BM25Search}(q_1), F, n))$ 
8 end
9 if  $v$  is true then
10   $G.append(\text{PostFilter}(\text{DenseSearch}(C_{\text{vis}}, \text{Embed}_{\text{vl}}(q_v)), F, n))$ 
11 end
12  $L \leftarrow \text{RRF}(G)$    $L \leftarrow \text{TypePrior}(L, q_v)$  // cộng khoản thưởng theo loại nội dung
13  $L \leftarrow \text{DiversifyByFile}(L, k, 2)$    $L \leftarrow \text{ExpandContext}(L)$    $L \leftarrow$ 
    $\text{CompressExtractive}(L, Q)$ 
14 return  $L[1..k]$ 

```

3.7 Sinh câu trả lời có căn cứ

3.7.1 Lập kế hoạch truy vấn

Ở chế độ hỏi đáp, hệ thống có thể dùng chính Qwen3-1.7B để lập kế hoạch truy vấn trước khi truy xuất. Mô hình được yêu cầu trả về duy nhất một đối tượng JSON gồm ba khóa: *rewritten* (câu hỏi được viết lại cho rõ nghĩa), *subqueries* (tối đa

3 truy vấn con; câu lệnh (prompt) yêu cầu chỉ dùng khi câu hỏi gồm nhiều phần độc lập, và với câu hỏi dạng liệt kê tài liệu hệ thống có thể bổ sung tối đa 2 truy vấn con dựng theo luật nếu mô hình không đưa ra truy vấn con nào) và `step_back` (một câu hỏi khái quát hơn). Câu lệnh dẫn dắt yêu cầu rõ ràng không bịa đề bài, không bịa nội dung bài giảng và không viết câu trả lời giả. Nếu mô hình không trả về JSON hợp lệ hoặc gặp lỗi, hệ thống dùng nguyên câu hỏi gốc. Câu trả lời cuối cùng vẫn được sinh từ câu hỏi gốc của người học. Bước này gọi mô hình với tối đa 256 đơn vị văn bản mới; hai chức năng phụ là HyDE và vòng truy xuất lại (tối đa một lần bổ sung, khi mô hình phản hồi rằng ngữ cảnh còn thiếu) đều mặc định tắt.

3.7.2 Ngữ cảnh và câu lệnh dẫn dắt

Các kết quả truy xuất được trình bày cho mô hình dưới dạng các khối đánh số, mỗi khối có tiêu đề gồm thứ tự, loại nội dung, đường dẫn tương đối, số trang (nếu có) và mốc thời gian (nếu có), ví dụ [Đoạn 2 | video_segment | assets/.../buoi_1.mp4 @300-330s], theo sau là nội dung. Tổng độ dài ngữ cảnh bị giới hạn ở 10 000 ký tự, và hệ thống cung cấp thêm danh sách các tệp nguồn. Số kết quả dùng để sinh câu trả lời mặc định là $\max(5, 8) = 8$.

Câu lệnh dẫn dắt hệ thống bằng tiếng Việt nêu bốn vai trò của trợ lý (nhận biết ngữ cảnh môn học, khai thác đa phương thức, trả lời có căn cứ và hỗ trợ học tập) cùng các ràng buộc: chỉ dựa trên ngữ cảnh và danh sách tệp nguồn; không bịa chương, lộ trình hay đường dẫn; khi người học xin bài tập thì trích hoặc liệt kê đề từ ngữ cảnh chứ không tạo đề mới; chỉ trích dẫn bằng đường dẫn tương đối kèm số trang hoặc mốc thời gian, không dùng liên kết markdown hay địa chỉ URL; và liên kết các nguồn bổ sung cho nhau. Chế độ suy nghĩ của Qwen3-1.7B được tắt và việc sinh dùng giải mã tham lam; các đoạn suy nghĩ còn sót (nếu có) được lọc khỏi luồng truyền phát theo từng phần.

3.7.3 Trả lời dựa trên ảnh

Khi việc tìm kiếm bao gồm cả không gian thị giác (tức là không bật chế độ chỉ văn bản) và kết quả truy xuất chứa ảnh trang hoặc ảnh hình của tài liệu PDF, PPT, PPTX hoặc DOCX mà tệp ảnh còn tồn tại, hệ thống chuyển sang mô hình ngôn ngữ thị giác (Vision-language model - VLM) Qwen3-VL-2B-Instruct: giải phóng mô hình văn bản khỏi bộ nhớ, nạp mô hình thị giác và cung cấp tối đa 3 ảnh cùng với phần ngữ cảnh văn bản. Mô hình được yêu cầu chỉ kết luận điều nhìn thấy hoặc có trong ngữ cảnh và trích dẫn ảnh bằng ký hiệu [V1], [V2] và văn bản bằng [T1], [T2]. Kết quả từ video không được gửi vào mô hình thị giác; video vẫn đi theo đường phiên âm và văn bản nhận dạng ký tự.

3.7.4 Giao diện lập trình ứng dụng

API được xây dựng bằng FastAPI. Điểm cuối POST `/v1/ask` mặc định truyền câu trả lời theo luồng bằng sự kiện do máy chủ gửi (Server-sent events - SSE) với các sự kiện ở **Bảng 3.5**; điểm cuối POST `/v1/search` chỉ trả về kết quả truy xuất; GET `/v1/stats` trả về thông kê kho vector; và GET `/v1/files/{đường dẫn}` phục vụ tệp học liệu và tệp trung gian, chỉ trong hai thư mục `assets/` và `storage/` và từ chối các đường dẫn thoát khỏi thư mục gốc. Khóa API là tùy chọn (tiêu đề `X-API-Key`) và chỉ bảo vệ các điểm cuối `/v1/ask`, `/v1/search` và `/v1/stats`; điểm cuối phục vụ tệp và điểm cuối kiểm tra sức khỏe không yêu cầu khóa, để thẻ phát video của trình duyệt phát được tệp. Mặc định API chỉ tìm trên văn bản (`text_only=true`) để tiết kiệm bộ nhớ. Mỗi lần chỉ một yêu cầu suy luận được thực hiện tại một thời điểm và dịch vụ chạy bằng một tiến trình.

Bảng 3.5: Các sự kiện truyền theo luồng của điểm cuối hỏi đáp

Sự kiện	Nội dung
status	Giai đoạn: enhancing, retrieving hoặc generating (theo cách cài đặt hiện tại, hai giá trị đầu được phát sau khi bước truy xuất đã hoàn tất, nên không phản ánh tiến độ theo thời gian thực)
query	Kế hoạch truy vấn (bản viết lại, truy vấn con, câu hỏi khái quát)
sources	Danh sách trích dẫn và danh sách tệp nguồn
delta	Một phần văn bản của câu trả lời
done, error	Kết thúc thành công hoặc thông báo lỗi

Mỗi kết quả truy xuất được chuyển thành một trích dẫn gồm mã, thứ tự, loại nội dung, điểm, tiêu đề (tên tệp), đoạn trích tối đa 240 ký tự và vị trí (số trang, thời điểm bắt đầu và kết thúc, nhãn dạng p.3 hoặc 12:42-14:05), cùng một tài nguyên gắn với tệp nguồn có đường dẫn tải xuống và đường dẫn xem. Đường dẫn xem của video có dạng `#t=bắt đầu,kết thúc`, của PDF có dạng `#page=số trang`, và của slide là ảnh xem trước nếu kết quả có ảnh đi kèm (ngược lại là đường dẫn tải xuống). Nhờ đó giao diện người dùng có thể mở đúng đoạn video hoặc đúng trang mà câu trả lời viện dẫn.

3.8 Khung đánh giá truy xuất không rò rỉ dữ liệu

Để đo chất lượng truy xuất mà không để hệ thống nhìn thấy đáp án, chúng tôi tách quy trình đánh giá thành hai giai đoạn.

1. *Chuẩn bị truy vấn.* Từ tập câu hỏi có nhãn, lệnh `prepare-retrieval-queries` sinh ra một tập JSONL chỉ gồm ba trường `question_id` (gán tuần tự Q001, Q002, ...), `question` và `course_id`. Bộ nạp truy vấn từ chối tập nếu chứa bất kỳ trường nào khác, do đó nhãn chuẩn (ground truth), nhãn có thể trả lời và bằng chứng không thể lọt vào bộ truy xuất.
2. *Truy xuất và chấm điểm.* Lệnh `benchmark-retrieve` chạy một cấu hình truy xuất trên tập truy vấn và lưu tối đa Top- K kết quả của từng câu (K mặc định là 10 và không được nhỏ hơn 10), kèm mã băm SHA-256 của tập truy vấn ghi trong từng dòng kết quả để có thể kiểm tra hai hệ thống dùng cùng một tập (hệ thống không tự động so sánh các mã này). Chỉ sau khi truy xuất hoàn tất, lệnh `score-retrieval` mới đọc nhãn chuẩn để chấm điểm.

Cấu hình khi chạy đánh giá. Lệnh `benchmark-retrieve` gọi trực tiếp bộ truy xuất (nên không có bước lập kế hoạch truy vấn) và ghi đè một số thiết lập so với cấu hình mặc định ở **Mục 3.6**: tắt mở rộng và nén ngữ cảnh; bật lọc theo môn học trước khi xếp hạng (trừ khi dùng tùy chọn `-no-course-filter`); và tăng số ứng viên của mỗi danh sách lên $\max(\text{giá trị hiện hành}, 10K)$, tức 100 khi $K = 10$. Hồ sơ baseline tắt BM25, nhánh thị giác và bộ xếp hạng lại Qwen nhưng vẫn giữ khoản thưởng theo loại nội dung và bước đa dạng theo tập; hồ sơ proposed bật BM25 và nhánh thị giác, và bộ xếp hạng lại Qwen chỉ được bật khi có tùy chọn `-rerank`. Đây là cấu hình của bộ đánh giá chuẩn (benchmark) dùng trong thực nghiệm.

Nhãn chuẩn và tài nguyên chưa được lập chỉ mục. Nhãn chuẩn của một câu là danh sách bằng chứng, mỗi bằng chứng gồm mã tài nguyên và, khi có, số trang, số slide hoặc khoảng thời gian. Khi nhãn “có thể trả lời” của một câu bị bỏ trống, chính sách suy luận mặc định coi câu có bằng chứng là có thể trả lời và câu có bằng chứng rỗng là không thể trả lời từ học liệu. Các câu không thể trả lời được tách riêng và không tính vào $Precision@K$ và $Recall@K$ vì tập kết quả liên quan của chúng rỗng. Câu có thể trả lời nhưng có ít nhất một tài nguyên bằng chứng chưa được lập chỉ mục bị loại khỏi điểm trung bình, vì hệ thống không thể trả về thứ chưa tồn tại trong chỉ mục.

Kết quả liên quan và các chỉ số. Một kết quả truy xuất được coi là liên quan tới một bằng chứng khi mã tài nguyên (sau chuẩn hóa) trùng nhau và, nếu bằng

chúng có số trang hoặc số slide thì con số đó bằng chính xác, và nếu bằng chúng có khoảng thời gian thì khoảng thời gian của kết quả giao với khoảng đó. Với một câu hỏi và mức cắt $K \in \{1, 5, 10\}$:

$$Precision@K = \frac{r_K}{K}, \quad Recall@K = \frac{m_K}{|E|}, \quad F1@K = \frac{2 \cdot Precision@K \cdot Recall@K}{Precision@K + Recall@K} \quad (3.4)$$

trong đó r_K là số kết quả liên quan trong K kết quả đầu, m_K là số bằng chứng riêng biệt được ít nhất một trong K kết quả đó khớp, và $|E|$ là tổng số bằng chứng của câu hỏi. Mẫu số của $Precision@K$ luôn là K kể cả khi hệ thống trả về ít hơn K kết quả; $F1@K$ bằng 0 khi cả hai bằng 0. Điểm của hệ thống là trung bình macro trên các câu hỏi được chấm. Các định nghĩa này theo cách dùng chuẩn trong truy xuất thông tin [24]. Ngoài ra, chúng tôi báo cáo thêm tỷ lệ trúng (hit rate) tại K , là phần các câu hỏi có ít nhất một kết quả liên quan trong K kết quả đầu, một đại lượng suy ra được từ số kết quả liên quan của từng câu và được tính bằng các công cụ thống kê đi kèm khóa luận (ví dụ `tools/retrieval_stats_v7.py` cho bộ câu hỏi hiện tại — **Chương 4**; lệnh chấm điểm của hệ thống không tính đại lượng này).

3.9 Hạn chế của thiết kế hiện tại

Dựa trên việc đọc mã nguồn, chúng tôi ghi nhận các hạn chế sau; chúng đồng thời là cơ sở cho các hướng phát triển ở **Chương 5**.

- *Siêu dữ liệu nghèo*. Ngoài môn học, loại nội dung và vị trí, hệ thống không ghi chương, tuần, mục tiêu học tập, độ khó, phiên bản học liệu, độ tin cậy của phiên âm hay nhận dạng ký tự, cũng như quyền truy cập.
- *Tính không thích nghi của cơ chế hợp nhất RRF (Non-adaptive RRF)*: Thuật toán RRF hiện tại áp dụng trọng số cố định mà chưa phân biệt được loại câu hỏi hay độ tin cậy riêng biệt của từng nguồn dữ liệu. Việc ưu tiên dữ liệu video vẫn phụ thuộc vào tập từ khóa quy ước và các hệ số điểm thưởng (**Bảng 3.4**).
- *Giới hạn trong phương pháp phân tách chỉ mục BM25 (Syllable-level Indexing)*: Do bộ chỉ mục BM25 thực hiện phân tách chuỗi theo các ký tự đặc biệt mà không tích hợp bộ tách từ tiếng Việt (*Word Segmenter*), hệ thống đang xử lý từng âm tiết như một đơn vị độc lập. Đây là một yếu tố có thể ảnh hưởng đến độ chính xác truy xuất và cần được đánh giá định lượng trong các nghiên cứu mở rộng.
- *Tính nhạy của biến số nhận dạng văn bản $o(c)$* : Do cơ chế OCR trên khung hình video được trích xuất theo chu kỳ tối thiểu 30 giây, biến số $o(c)$ trong

Công thức 3.2 nhận giá trị bằng 1 ngay cả khi khung hình không chứa văn bản (nếu trước đó đã xuất hiện văn bản không rỗng). Điều này dẫn đến việc thuật toán chưa phân biệt triệt để giữa trường hợp “văn bản không tồn tại” và “văn bản đã thay đổi”. Tuy nhiên, ở thiết lập tham số mặc định, yếu tố này không làm ảnh hưởng đến tập khung hình đầu ra (**Mục 3.4**).

- *Tác động của tham số chọn khung hình mặc định*: Khi thiết lập kích thước cửa sổ 30 giây (tối đa 3 khung hình ứng viên) và đặt $M = 3$, điểm đánh giá tại **Công thức 3.2** không tạo ra sự lọc bổ sung nào ngoài bước loại trùng lặp ban đầu. Yếu tố này đòi hỏi các thực nghiệm bổ sung với kích thước M nhỏ hơn để xác định rõ hiệu quả lọc của công thức.
- *Hạn chế xử lý đa định dạng từ thư viện Docling*: Thư viện Docling hiện chưa hỗ trợ sinh ảnh trang (*page image*) cho các định dạng PPTX và DOCX (**Mục 3.3**). Do đó, nhánh phân tích thị giác chỉ áp dụng được trên các hình ảnh nhúng (*embedded images*) của slide PPTX, và tính năng OCR dự phòng trên ảnh trang hiện chỉ tối ưu cho định dạng PDF.
- *Chú thích ảnh phụ thuộc vào Docling*. Bộ nạp ưu tiên `caption_text()` và `captions`; nếu phần tử hình không có chú thích, trường `caption` để trống.
- *Lọc theo tệp không áp dụng cho BM25*. Khi chỉ định một tệp nguồn, các kết quả BM25 từ tệp khác vẫn tham gia hợp nhất.
- *Bài tập*. Các tệp bài tập được xử lý như văn bản thông thường; hệ thống không tách đề, gợi ý, lời giải và mức độ khó, cũng không kiểm soát việc tiết lộ đáp án.
- *Video chưa được đưa vào trả lời bằng ảnh*. Khung hình video chỉ tham gia truy xuất; mô hình thị giác chỉ đọc ảnh trang và ảnh hình của tài liệu.
- *Triển khai một tiến trình*. API xử lý tuần tự từng yêu cầu suy luận, phù hợp với thiết bị có bộ nhớ hạn chế nhưng không phù hợp với tải lớn.

Chương 4

THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Tóm tắt chương

Chương này trình bày toàn bộ quá trình thực nghiệm và đánh giá hệ thống, bao gồm thiết lập môi trường, chuẩn bị dữ liệu, cấu hình các mô hình so sánh và các kiểm định thống kê liên quan. Chất lượng sinh câu trả lời và ngữ cảnh truy xuất được đánh giá bằng bốn chỉ số tham khảo từ RAGAs: độ trung thực với ngữ cảnh (*Faithfulness*), độ liên quan của câu trả lời (*Answer Relevance*), độ chính xác ngữ cảnh (*Context Precision*) và độ thu hồi ngữ cảnh (*Context Recall*).

Kết quả thực nghiệm cho thấy kho học liệu đạt độ phủ 100% trên bộ câu hỏi đánh giá. Đặc biệt, cấu hình lai đa phương thức kết hợp xếp hạng lại (*Hybrid Multimodal with Reranking*) cho hiệu năng vượt trội hơn hệ thống cơ sở ở các mức $K = 5$ và $K = 10$. Ý nghĩa thống kê được xác nhận thông qua khoảng tin cậy lấy mẫu lại (*Bootstrap*) không chứa giá trị 0. Các thí nghiệm trong chương được phân định rõ ràng giữa kết quả đã kiểm chứng và các định hướng nghiên cứu tiếp theo.

4.1 Mục tiêu và phạm vi của thực nghiệm

Thực nghiệm trả lời hai câu hỏi nghiên cứu đã nêu ở Mục 1.3.2. Với RQ1, chúng tôi so sánh ba cấu hình trên cùng bộ truy vấn, lưu tối đa Top-10 kết quả cho mỗi câu hỏi và chỉ đối chiếu với nhãn chuẩn (ground truth) sau khi truy xuất kết thúc; kết quả Precision, Recall, F1 và tỷ lệ trúng (hit rate) tại $K \in \{1, 5, 10\}$ được trình bày ở Bảng 4.4–4.6. Với RQ2, chúng tôi trình bày F1@10 theo nhóm câu hỏi và độ khó ở Bảng 4.7–4.8; đây là so sánh mô tả. Kết quả sinh câu trả lời được báo cáo riêng ở Mục 4.5.5.

4.2 Môi trường thực nghiệm

Thiết bị. Toàn bộ thực nghiệm chạy trên một máy MacBook Pro, chip Apple M1 Pro (10 lõi: 8 lõi hiệu năng và 2 lõi tiết kiệm điện), 16GB bộ nhớ hợp nhất, hệ điều hành macOS 27.0 (bản dựng 26A428). Cả bốn lần chạy truy xuất đều dùng khung tăng tốc đồ họa của Apple (Metal Performance Shaders - MPS) để nạp mô hình: nhật ký hệ thống xác nhận trực tiếp hai lần chạy có bật bộ xếp hạng lại (reranker) (nạp cả ba mô hình: biểu diễn văn bản, biểu diễn thị giác, xếp hạng lại).

Phần mềm. Môi trường Python 3.12.14 với PyTorch 2.14.0, Transformers 5.16.1, Sentence Transformers 6.0.1, ChromaDB 1.5.9, rank-bm25 0.2.2, langchain-huggingface 1.2.2, faster-whisper 1.2.1 và Docling 2.126.0. Các mô hình được nạp từ bộ nhớ đệm cục bộ ở chế độ ngoại tuyến (HF_HUB_OFFLINE=1, TRANSFORMERS_OFFLINE=1). Mã băm phiên bản (revision) đọc trực tiếp từ thư mục bộ nhớ đệm cục bộ: Qwen3-Embedding-0.6B — 97b0c61; Qwen3-VL-Embedding-2B — 9f2f7e7; Qwen3-Reranker-0.6B — e61197e; Qwen3-1.7B (dùng để sinh câu trả lời) — 70d244c. Hai mô hình biểu diễn vector (embedding) được nạp qua SentenceTransformer không chỉ định kiểu số nên dùng mặc định float32; bộ xếp hạng lại và mô hình sinh câu trả lời dùng float16 trên MPS (float32 trên CPU), theo mã nguồn (app/retrieval/reranker.py, app/generation/service.py).

4.3 Dữ liệu thực nghiệm

4.3.1 Kho học liệu

Trước thực nghiệm, toàn bộ chỉ mục ChromaDB, chỉ mục BM25 và sổ đăng ký lập chỉ mục được xóa và lập chỉ mục lại từ đầu. Kho học liệu gồm 69 tệp thuộc ba môn học: Cấu trúc rời rạc, Nhập môn Lập trình và Cấu trúc dữ liệu và Giải thuật, trong đó có 21 tệp PDF, 7 tệp PPTX, 7 tệp PPT (định dạng cũ, được chuyển đổi tạm thời sang PPTX bằng LibreOffice ở chế độ dòng lệnh ẩn chỉ để trích xuất nội dung — siêu dữ liệu lưu trong ChromaDB vẫn ghi đường dẫn và định dạng .ppt gốc), 4 tệp DOCX và 30 tệp video MP4. Toàn bộ 69/69 tệp được lập chỉ mục thành công, không có lỗi (**Bảng 4.1**). ChromaDB chứa 15 682 vector ở tập vector văn bản (5 782 đoạn văn bản, 97 bảng và 9 803 cửa sổ phiên âm video) và 12 793 vector ở tập vector thị giác (582 ảnh trang, 1 297 ảnh/hình và 10 914 khung hình video).

Bảng 4.1: Số tệp đã được lập chỉ mục, theo môn học và loại tệp (độ phủ 69/69, không lỗi)

Môn học	PDF	PPTX	PPT	DOCX	MP4	Tổng
Cấu trúc rời rạc	4	7	0	3	10	24
Nhập môn Lập trình	17	0	0	1	10	28
Cấu trúc dữ liệu và Giải thuật	0	0	7	0	10	17
Tổng	21	7	7	4	30	69

4.3.2 Bộ câu hỏi và nhãn chuẩn

Bộ câu hỏi `questions_draft_v7.json` gồm 400 bản ghi, mỗi bản ghi có các trường: câu hỏi, các nguồn cần thiết, danh sách bằng chứng, mã môn học, mục tiêu học tập, nhãn có thể trả lời, nhóm câu hỏi (bốn nhóm cân bằng, mỗi nhóm 100 câu: `video_grounded`, `slide_grounded`, `visual`, `cross_source`) và *difficulty* (`easy` 76 câu, `medium` 296 câu, `hard` 28 câu). Nhãn có thể trả lời nhận giá trị đúng ở toàn bộ 400/400 bản ghi; bộ câu hỏi này không có câu ngoài phạm vi. Các trường nguồn cần thiết và bằng chứng do các tác giả xác định, gán và kiểm định dựa trên học liệu gốc; chúng được dùng làm thông tin chuẩn trong đánh giá truy xuất và đánh giá theo khung RAGAs.

Bảng 4.2 cho biết phân bố câu hỏi theo nhóm câu hỏi và độ khó (*difficulty*).

Bảng 4.2: Phân bố 400 câu hỏi theo nhóm và theo độ khó

Nhóm câu hỏi	Số câu	Độ khó	Số câu
Dựa trên video (<i>video_grounded</i>)	100	Dễ (<i>easy</i>)	76
Dựa trên slide (<i>slide_grounded</i>)	100	Trung bình (<i>medium</i>)	296
Thị giác (<i>visual</i>)	100	Khó (<i>hard</i>)	28
Đa nguồn (<i>cross_source</i>)	100		
Tổng	400	Tổng	400

Nhãn chuẩn (bằng chứng, nguồn cần thiết) của bộ câu hỏi v7 do các tác giả trực tiếp xác định, gán và kiểm định dựa trên việc đối chiếu với học liệu gốc. Các nhãn này được dùng làm thông tin chuẩn khi chấm điểm truy xuất và đánh giá theo khung RAGAs.

4.3.3 Tập câu hỏi được chấm điểm

Sau khi áp dụng bảng ánh xạ mã tài nguyên và hoàn tất lập chỉ mục 7 tệp PPT, toàn bộ 400/400 câu có đủ tài nguyên bằng chứng trong chỉ mục — độ phủ kho học liệu đạt $400/400 = 100\%$, không có câu nào bị loại vì thiếu nguồn. Vì bộ câu hỏi này cũng không có câu ngoài phạm vi (**Mục 4.3**), điểm trung bình trong chương này được tính trên toàn bộ 400 câu, không có câu nào bị loại.

4.4 Cấu hình các hệ thống được so sánh

Ba cấu hình nhận cùng một đầu vào gồm câu hỏi và mã môn học, được chạy bằng lệnh `benchmark-retrieve` với $K = 10$, cùng không bật mở rộng/nén ngữ cảnh. **Bảng 4.3** liệt kê cấu hình của từng hệ thống. Ở hệ thống thứ ba, bộ xếp hạng lại Qwen3-Reranker-0.6B nhận đầu vào theo đúng mẫu hội thoại mà mô hình được huấn luyện để chấm điểm (vai trò `system/query/document`, qua `tokenizer.apply_chat_template()`).

Bảng 4.3: Cấu hình của ba hệ thống truy xuất được so sánh

Thành phần	Cơ sở	Lai	Lai + xếp hạng lại
Mã hệ thống	baseline	hybrid_norerank	hybrid_rerank_fixed
Dây trên văn bản (Qwen3-Embedding-0.6B)	Có	Có	Có
Thưa BM25 (rank-bm25)	Không	Có	Có
Thị giác (Qwen3-VL-Embedding-2B)	Không	Có	Có
Hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF), hằng số 60, không trọng số	Không áp dụng (một danh sách)	Có	Có
Xếp hạng lại (Qwen3-Reranker-0.6B)	Tắt	Tắt	Bật, theo mẫu hội thoại
Thưởng theo loại nội dung	Bật	Bật	Bật
Mở rộng và nén ngữ cảnh	Tắt	Tắt	Tắt
Lọc theo môn học	Bật	Bật	Bật
Số ứng viên mỗi danh sách (fetch_k)	100	100	100
Số kết quả cuối; tối đa mỗi tệp	10; 2	10; 2	10; 2
Sinh câu trả lời	Không chạy	Không chạy	Không chạy

Mỗi hệ thống được chạy một lần trên toàn bộ 400 câu. Khoản thưởng theo loại nội dung là một thành phần của bộ truy xuất luôn hoạt động theo mã nguồn (không tắt được qua cấu hình bộ đánh giá chuẩn (benchmark)), áp dụng cho các câu chứa từ khoá hỏi về bài giảng.


4.5 Kết quả và nhận xét

4.5.1 Kết quả truy xuất trung bình

Bảng 4.4 trình bày điểm trung bình macro trên toàn bộ 400 câu, làm tròn đến bốn chữ số thập phân; chữ đậm đánh dấu hệ thống có giá trị cao nhất ở cột đó. **Hình 4.1** minh hoạ cùng số liệu.

Bảng 4.4: Điểm trung bình macro trên 400 câu, ba hệ thống (xem tên đầy đủ ở Bảng 4.3)

Hệ thống	P@1	R@1	F1@1	P@5	R@5	F1@5	P@10	R@10	F1@10
Cơ sở	0,3075	0,2296	0,2528	0,0885	0,3185	0,1341	0,0550	0,3515	0,0916
Lai	0,2425	0,1783	0,1974	0,0860	0,3092	0,1304	0,0500	0,3517	0,0854
Lai + XHL	0,3200	0,2446	0,2670	0,1240	0,4550	0,1887	0,0655	0,4671	0,1121



Hình 4.1: So sánh P/R/F1 tại $K \in \{5, 10\}$ giữa ba hệ thống truy xuất

Hệ thống “Lai + xếp hạng lại” cao nhất ở toàn bộ 9/9 chỉ số, kể cả $Recall@10$ (0,4671, cao hơn “Lai” 0,1154 — khoảng tin cậy lấy mẫu lại không chứa 0, **Bảng 4.5**).

4.5.2 Kiểm định thống kê

Bộ câu hỏi v7 không có bản ghi trùng nội dung truy vấn (400 bản ghi, 400 cặp môn học/câu hỏi khác nhau), nên 400 bản ghi được coi là 400 đơn vị lấy mẫu độc lập, không cần tách lấy mẫu lại theo truy vấn và theo bản ghi. Chúng tôi tính khoảng tin cậy cho hiệu số giữa từng cặp hệ thống bằng phương pháp lấy mẫu lại ghép cặp [7], một hướng đã được so sánh với các kiểm định khác cho đánh giá truy xuất thông tin [29]: lấy mẫu có hoàn lại 400 bản ghi 10 000 lần, giữ nguyên cặp kết quả của hai hệ thống trên cùng một bản ghi, tính hiệu số trung bình của từng chỉ số, và lấy khoảng giữa phân vị 2,5% và 97,5% làm khoảng tin cậy 95%, với giá trị khởi tạo ngẫu nhiên (random seed) 20260930. Mã nguồn tính toán lưu trong tools/retrieval_stats_v7.py và cho ra đúng các số dưới đây khi chạy lại từ các tệp kết quả gốc. **Bảng 4.5** trình bày ba so sánh: Cơ sở so với Lai (hiệu quả riêng của BM25 và thị giác không xếp hạng lại), Cơ sở so với Lai + XHL (hiệu quả

của toàn bộ cấu hình đề xuất), và Lai so với Lai + XHL (hiệu quả riêng của việc thêm xếp hạng lại).

Bảng 4.5: Hiệu số và khoảng tin cậy 95% (lấy mẫu lại ghép cặp, 400 bản ghi, 10 000 lần lấy mẫu)

Chỉ số	Cơ sở → Lai	Cơ sở → Lai+XHL	Lai → Lai+XHL
<i>Precision@1</i>	−0,0650 [−0,1050; −0,0250]	+0,0125 [−0,0375; +0,0625]	+0,0775 [+0,0275; +0,1275]
<i>Recall@1</i>	−0,0512 [−0,0846; −0,0175]	+0,0150 [−0,0258; +0,0569]	+0,0663 [+0,0256; +0,1075]
<i>F1@1</i>	−0,0554 [−0,0904; −0,0213]	+0,0142 [−0,0283; +0,0561]	+0,0696 [+0,0275; +0,1111]
<i>Precision@5</i>	−0,0025 [−0,0120; +0,0065]	+0,0355 [+0,0240; +0,0475]	+0,0380 [+0,0275; +0,0490]
<i>Recall@5</i>	−0,0094 [−0,0444; +0,0250]	+0,1365 [+0,0910; +0,1812]	+0,1458 [+0,1042; +0,1871]
<i>F1@5</i>	−0,0037 [−0,0175; +0,0104]	+0,0546 [+0,0367; +0,0724]	+0,0583 [+0,0419; +0,0745]
<i>Precision@10</i>	−0,0050 [−0,0100; +0,0000]	+0,0105 [+0,0040; +0,0173]	+0,0155 [+0,0103; +0,0208]
<i>Recall@10</i>	+0,0002 [−0,0331; +0,0338]	+0,1156 [+0,0712; +0,1610]	+0,1154 [+0,0746; +0,1575]
<i>F1@10</i>	−0,0062 [−0,0143; +0,0021]	+0,0205 [+0,0097; +0,0315]	+0,0267 [+0,0176; +0,0358]

Ghi chú: số in đậm là khoảng không chứa 0. Chưa hiệu chỉnh cho việc so sánh nhiều chỉ số và nhiều cặp hệ thống cùng lúc.

Bảng 4.5 cho thấy ba điều. Thứ nhất, so sánh Cơ sở với Lai (chưa xếp hạng lại) có khoảng tin cậy chứa 0 ở $K = 5$ và $K = 10$, và khoảng tin cậy nằm hoàn toàn ở phía âm ở $K = 1$ (Lai thấp hơn Cơ sở có ý nghĩa thống kê tại $K = 1$) — nghĩa là riêng việc thêm BM25 và thị giác, hợp nhất bằng RRF không trọng số, không cải thiện truy xuất so với truy xuất dày (dense retrieval) có lọc theo môn học, và còn làm giảm chất lượng ở $K = 1$. Thứ hai, so sánh Cơ sở với Lai + XHL có khoảng tin cậy không chứa 0 và hoàn toàn dương ở cả 6 chỉ số tại $K = 5$ và $K = 10$ (chỉ chứa 0 ở $K = 1$) — đây là bằng chứng thống kê đầu tiên trong khóa luận cho thấy cấu hình đề xuất vượt cơ sở, nhất quán ở cả *Precision*, *Recall* và *F1*. Thứ ba, so sánh Lai với Lai + XHL cho kết quả tương tự và còn rõ hơn ở $K = 1$ (khoảng tin cậy dương, không chứa 0 ở cả 9/9 chỉ số) — cho thấy phần lớn cải thiện đến từ bước xếp hạng lại, không phải từ BM25 hay nhánh thị giác.

4.5.3 Tỷ lệ trùng

Bảng 4.6 báo cáo tỷ lệ trùng tại K , là phần trong 400 câu có ít nhất một kết quả liên quan trong K kết quả đầu tiên.


Hệ thống Lai + XHL có tỷ lệ trùng tại $K = 10$ là 56,25%, cao hơn tuyệt đối 13,5 điểm phần trăm so với hệ thống cơ sở (42,75%); các hệ thống còn lại đều thấp hơn hoặc gần bằng hệ thống cơ sở. Dù vậy, mức tuyệt đối của tỷ lệ trùng vẫn chưa cao — hơn 40% số câu của hệ thống tốt nhất không có bất kỳ kết quả liên quan nào trong Top-10 — và cần đọc cùng **Bảng 4.4**.

Bảng 4.6: Tỷ lệ trùng tại K trên 400 câu, ba hệ thống

Hệ thống	$K = 1$	$K = 5$	$K = 10$
Cơ sở	0,3075	0,3925	0,4275
Lai	0,2425	0,3975	0,4375
Lai + XHL	0,3200	0,5525	0,5625

4.5.4 Kết quả theo nhóm câu hỏi và theo độ khó

Hình 4.2 và Hình 4.3 so sánh $F1@10$ giữa hệ thống cơ sở và hệ thống Lai + XHL theo nhóm câu hỏi và theo độ khó; Bảng 4.7 và Bảng 4.8 liệt kê đầy đủ số liệu của cả ba hệ thống.

**Hình 4.2:** $F1@10$ theo nhóm câu hỏi, Cơ sở so với Lai + XHL


Cấu hình Lai + XHL cao nhất ở cả bốn nhóm câu hỏi và ở hai trong ba mức độ khó (dễ, trung bình); riêng ở nhóm khó (28 câu, cỡ mẫu nhỏ), hệ thống Lai (0,1104) và hệ thống cơ sở (0,1093) nhỉnh hơn một chút so với Lai + XHL (0,0974). Nhóm *video_grounded* là nhóm yếu nhất ở cả ba hệ thống — $F1@10$ cao nhất của nhóm này (0,0461) vẫn thấp hơn nhiều so với các nhóm còn lại; nguyên nhân được thảo luận ở Mục 4.6.

4.5.5 Kết quả sinh câu trả lời (generation-level)

Để có kết quả đánh giá đầu-cuối (end-to-end evaluation) đầu tiên của khóa luận, với cấu hình truy xuất tốt nhất đo được (Lai + XHL), chúng tôi chạy toàn bộ luồng

Bảng 4.7: F1@10 theo nhóm câu hỏi, ba hệ thống

Hệ thống	Đa nguồn	Slide	Video	Thị giác
Cơ sở	0,1697	0,1161	0,0141	0,0667
Lai	0,1557	0,1088	0,0211	0,0562
Lai + XHL	0,1839	0,1388	0,0461	0,0797



Hình 4.3: F1@10 theo độ khó, Cơ sở so với Lai + XHL

sinh câu trả lời (tăng cường câu hỏi, HyDE, truy xuất, xếp hạng lại, sinh câu trả lời bằng Qwen3-1.7B) trên 400 câu, chỉ dùng ngữ cảnh văn bản (không bật nhánh trả lời bằng ảnh), lấy tối đa 8 kết quả truy xuất làm ngữ cảnh cho mỗi câu (tham số `generation_k=8`, khác với $K = 10$ dùng ở phần truy xuất thuần). RAGAs được sử dụng làm khung đánh giá với bốn chỉ số: độ trung thực với ngữ cảnh, độ liên quan của câu trả lời, độ chính xác ngữ cảnh và độ thu hồi ngữ cảnh. Các chỉ số được tính từ câu hỏi, ngữ cảnh truy xuất, câu trả lời sinh ra và thông tin chuẩn của bộ đánh giá; kết quả trung bình được trình bày ở **Bảng 4.9**.

Ngoài ra, *độ chính xác trích dẫn* và *độ phủ trích dẫn* đo chất lượng của tập kết quả truy xuất thực sự được đưa vào ngữ cảnh cho mô hình (không phải phân tích chuỗi trích dẫn trong văn bản câu trả lời), so với bằng chứng chuẩn, dùng lại đúng hàm tính *Precision/Recall@K* và bảng ánh xạ mã tài nguyên đã dùng ở phần truy xuất (**Mục 4.3**). **Bảng 4.9** tổng hợp kết quả trên 400 câu.

Về phân bố điểm RAGAs. Cả độ trung thực với ngữ cảnh và độ liên quan của câu trả lời đều có phân bố gần như nhị phân: trong 399/400 câu có kết quả, độ trung thực với ngữ cảnh nhận đúng giá trị 0,0 ở 198 câu và đúng giá trị 1,0 ở 201 câu

Bảng 4.8: F1@10 theo độ khó, ba hệ thống

Hệ thống	Dễ (76)	Trung bình (296)	Khó (28)
Cơ sở	0,0865	0,0913	0,1093
Lai	0,0833	0,0836	0,1104
Lai + XHL	0,1326	0,1082	0,0974

Bảng 4.9: Kết quả sinh câu trả lời trên 400 câu, cấu hình Lai + XHL, chỉ ngữ cảnh văn bản

Chỉ số	Giá trị
Độ trung thực với ngữ cảnh	0,5038
Độ liên quan của câu trả lời	0,5013
Độ phủ theo tệp (<i>path recall@10</i>)	0,9463
Độ chính xác theo tệp (<i>path precision</i>)	0,1612
Độ chính xác ngữ cảnh (trung bình)	0,0847
Độ thu hồi ngữ cảnh (trung bình)	0,4683

(0 câu nhận giá trị trung gian); độ liên quan của câu trả lời nhận 0,0 ở 199 câu và 1,0 ở 200 câu. Vì vậy, con số 0,5038 nên được đọc là “khoảng một nửa số câu có điểm hoàn toàn đạt, nửa còn lại có điểm hoàn toàn không đạt”, không phải “mỗi câu đạt khoảng một nửa”. Phân bố này cho thấy các chỉ số chất lượng câu trả lời trong cấu hình thực nghiệm có xu hướng tập trung ở hai cực thay vì phân bố liên tục như yêu cầu trong câu lệnh (prompt) dẫn dắt, và cần được lưu ý khi diễn giải kết quả (**Mục 4.6**).

Về chênh lệch giữa các chỉ số phủ. Độ thu hồi ngữ cảnh của RAGAs (0,4683) nằm giữa *path recall@10* (0,9463, chỉ cần đúng tệp) và *recall@10* đo ở phần truy xuất thuần của cùng hệ thống (0,4671, **Bảng 4.4**, yêu cầu khớp đúng trang/slide/khoảng thời gian) — đúng như kỳ vọng vì ba chỉ số này khác nhau về độ chặt của tiêu chí khớp, không phải mâu thuẫn với nhau.

Bảng 4.10 và **Bảng 4.11** trình bày độ phủ/độ chính xác theo tệp, theo nhóm câu hỏi và theo độ khó (báo cáo hiện tại chưa tách độ trung thực với ngữ cảnh/độ liên quan của câu trả lời theo nhóm).

Nhóm *video_grounded* tiếp tục là nhóm yếu nhất ở mọi mức *K* (nhất quán với kết quả truy xuất thuần ở Mục trước). Nhóm *hard* (28 câu, cỡ mẫu nhỏ) có *path_recall* cao nhất trong ba mức độ khó; vì cỡ mẫu nhỏ, chúng tôi không coi đây là kết luận vững mà chỉ ghi nhận để điều tra thêm.

Bảng 4.10: Độ phủ/độ chính xác theo tệp, theo nhóm câu hỏi (sinh câu trả lời)

Nhóm	path_recall@1	path_recall@5	path_recall@10	path_precision
Video (<i>video_grounded</i>)	0,25	0,71	0,82	0,107
Slide (<i>slide_grounded</i>)	0,79	0,99	1,00	0,135
Thị giác (<i>visual</i>)	0,62	0,99	0,99	0,135
Đa nguồn (<i>cross_source</i>)	0,43	0,96	0,975	0,267

Bảng 4.11: Độ phủ/độ chính xác theo tệp, theo độ khó (sinh câu trả lời)

Độ khó	path_recall@1	path_recall@5	path_recall@10	path_precision
Dễ (76)	0,566	0,934	0,947	0,129
Trung bình (296)	0,484	0,899	0,941	0,172
Khó (28)	0,821	1,00	1,00	0,129

4.6 Phân tích và thảo luận

Về giả thuyết đa phương thức. Kết quả tách bạch được hai hiệu ứng riêng (**Mục 4.5.2**). Riêng việc thêm BM25 và truy xuất trên không gian thị giác, hợp nhất bằng RRF không trọng số nhưng chưa xếp hạng lại, không cải thiện so với truy xuất dày có lọc theo môn học — khoảng tin cậy chứa 0 ở $K = 5, 10$ và còn âm có ý nghĩa ở $K = 1$. Ngược lại, thêm bước xếp hạng lại với đầu vào định dạng đúng theo mẫu hội thoại của mô hình mang lại cải thiện có ý nghĩa thống kê, nhất quán ở *Precision*, *Recall* và *F1* tại $K = 5$ và $K = 10$. Nói cách khác, phần lớn lợi ích đo được trong thực nghiệm này đến từ bước xếp hạng lại được định dạng đúng, không phải từ việc hợp nhất nhiều danh sách truy xuất.

Về giới hạn cấu trúc của *Precision@K*. Do mỗi tệp chỉ được giữ tối đa 2 kết quả trong Top-K (lọc đa dạng theo tệp) và phần lớn câu hỏi chỉ có một hoặc hai nguồn bằng chứng, *Precision@K* ở $K = 5, 10$ bị giới hạn cấu trúc: với một bản ghi chỉ có một bằng chứng, số kết quả liên quan tối đa là 2, nên *Precision@10* khó vượt 0,2. Vì vậy các giá trị *Precision@5*, *Precision@10* tuyệt đối thấp một phần là hệ quả của thiết lập truy xuất, không riêng của thuật toán, và nên đọc cùng *Recall@K* và tỷ lệ trùng.

Về nhóm *video_grounded*. Đây là nhóm yếu nhất ở cả ba hệ thống truy xuất và ở cả phần sinh câu trả lời (*F1@10* cao nhất của nhóm này chỉ 0,0461, so với 0,0797–0,1839 ở các nhóm còn lại). Chúng tôi chưa có bằng chứng thực nghiệm về nguyên nhân; các giả thuyết có thể kiểm chứng gồm: cửa sổ phiên âm video (30 giây) quá thô so với yêu cầu khớp đúng khoảng thời gian của tiêu chí chấm điểm, hoặc câu hỏi nhóm này đòi hỏi mốc thời gian chính xác hơn mức mà truy xuất ở

cấp đoạn phiên âm có thể cung cấp. Cần thí nghiệm riêng trước khi kết luận.

Về chất lượng sinh câu trả lời. Kết quả RAGAs của cấu hình này cần được diễn giải cùng với phân bố điểm gần như nhị phân của độ trung thực với ngữ cảnh và độ liên quan của câu trả lời (**Mục 4.5.5**); hai chỉ số này không phân bố đều trên thang liên tục $[0, 1]$ như yêu cầu trong câu lệnh dẫn dắt. Độ chính xác ngữ cảnh ở mức thấp (0,0847) phần lớn là hệ quả của mẫu số: mỗi câu đưa tới đa 8 kết quả vào ngữ cảnh trong khi số bằng chứng chuẩn trung bình mỗi câu nhỏ hơn nhiều, nên không nên so trực tiếp con số này với $Precision@K$ của phần truy xuất thuần (dùng $K = 10$ và tiêu chí khớp khác).

4.7 Ưu điểm và hạn chế

Ưu điểm

- *Quy trình đánh giá không rò rỉ và có thể tái lập:* tập truy vấn chỉ có ba trường, nhãn chuẩn chỉ được đọc sau khi truy xuất, tập truy vấn có mã băm và quá trình chạy có thể tiếp tục sau khi bị gián đoạn (**Mục 3.8**).
- *Kho học liệu đầy đủ:* độ phủ 100% đối với bộ câu hỏi đánh giá, không có câu nào bị loại vì thiếu nguồn.
- *Tách bạch được hiệu ứng của từng thành phần:* ba cấu hình cho phép phân biệt hiệu ứng của việc hợp nhất đa phương thức (không rõ rệt) với hiệu ứng của xếp hạng lại (rõ rệt, có ý nghĩa thống kê).
- *Đánh giá cả truy xuất lẫn sinh câu trả lời:* không chỉ đánh giá khả năng tìm bằng chứng, mà còn đo độ trung thực, độ liên quan và chất lượng ngữ cảnh theo các chỉ số của RAGAs.
- *Trích dẫn có vị trí:* câu trả lời và kết quả tìm kiếm gắn với tệp, số trang hoặc mốc thời gian, giúp người học kiểm chứng (**Mục 3.7**).
- *Báo cáo trung thực:* kết quả được báo cùng khoảng tin cậy, kể cả các so sánh cho kết quả âm hoặc không có ý nghĩa thống kê (hợp nhất đa phương thức khi chưa xếp hạng lại), không chỉ nêu kết quả tích cực.

Hạn chế

- Mỗi hệ thống chỉ chạy một lần; chưa hiệu chỉnh kiểm định cho việc so sánh nhiều chỉ số và nhiều cặp hệ thống.

- Hai chỉ số chất lượng câu trả lời của RAGAs có phân bố gần như nhị phân thay vì liên tục.
- Nhóm câu hỏi *video_grounding* yếu ở mọi cấu hình đã đo, nguyên nhân chưa được kiểm chứng.
- Chưa đo biến thể HyDE + vòng lặp truy xuất lặp lại và biến thể trả lời bằng ảnh.
- Các hạn chế về thiết kế được nêu ở **Mục 3.9**.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Tóm tắt chương

Trong chương cuối này, chúng tôi tổng hợp những công việc đã thực hiện, đối chiếu với các mục tiêu đã đặt ra và đề xuất các hướng phát triển trong tương lai.

5.1 Kết luận

Khóa luận đã nghiên cứu và xây dựng một trợ lý ảo cho hệ thống e-learning dựa trên sinh tăng cường truy xuất (Retrieval-augmented generation - RAG) đa phương thức. Hệ thống nạp học liệu đa định dạng (tài liệu PDF, DOCX, PPTX và video bài giảng) vào một kho tri thức gồm hai chỉ mục vector và một chỉ mục từ vựng, truy xuất bằng bộ truy xuất lai (hybrid retrieval) hợp nhất bằng hợp nhất thứ hạng nghịch đảo (Reciprocal rank fusion - RRF) có lọc theo môn học, và sinh câu trả lời kèm trích dẫn có vị trí cụ thể, cùng API truyền phát câu trả lời (**Chương 3**). Chúng tôi cũng xây dựng một quy trình đánh giá truy xuất không rò rỉ dữ liệu, trong đó truy vấn và nhãn chuẩn (ground truth) được tách riêng.

Đối chiếu với bốn mục tiêu của khóa luận (**Mục 1.3.1**): mục tiêu tổ chức kho tri thức thống nhất và mục tiêu xây dựng bộ truy xuất kết hợp nhiều nguồn đã được hiện thực; mục tiêu sinh câu trả lời có căn cứ đã được hiện thực và đã được đánh giá bằng thực nghiệm (độ trung thực với ngữ cảnh (faithfulness), độ liên quan của câu trả lời (answer relevance), độ chính xác/độ phủ của trích dẫn — **Mục 4.5.5**), dù mới trên một cấu hình truy xuất duy nhất; mục tiêu đánh giá truy xuất đã được thực hiện trên bộ 400 câu hỏi v7, với toàn bộ 400 câu hợp lệ và độ phủ của kho học liệu đạt 100%.

Kết quả thực nghiệm cần được đọc thận trọng (**Chương 4**). Riêng việc thêm truy

xuất thưa (sparse retrieval) và truy xuất trên ảnh vào hệ thống cơ sở chỉ dùng văn bản, khi chưa xếp hạng lại, không tạo ra khác biệt có ý nghĩa thống kê ở $K = 5$ hay $K = 10$, và còn làm giảm chất lượng có ý nghĩa thống kê ở $K = 1$. Tuy nhiên, hệ thống đề xuất (có thêm bộ xếp hạng lại (reranker) Qwen3-Reranker-0.6B) vượt hệ thống cơ sở với khoảng tin cậy lấy mẫu lại (bootstrap) không chứa 0 ở phần lớn chỉ số tại $K = 5$ và $K = 10$ (**Mục 4.5**) — bằng chứng thống kê đầu tiên trong khóa luận cho thấy cấu hình đề xuất cải thiện chất lượng truy xuất, và phần lớn cải thiện này đến từ bước xếp hạng lại, không phải từ việc hợp nhất nhiều nguồn. Khóa luận cũng đã có kết quả đánh giá chất lượng câu trả lời được sinh và ngữ cảnh truy xuất theo khung RAGAs (**Mục 4.5.5**). Kết quả cho thấy phân bố điểm của hai chỉ số chất lượng câu trả lời gần như nhị phân; thực nghiệm mới đo trên một cấu hình truy xuất duy nhất và chỉ với ngữ cảnh văn bản, trong khi nhóm câu hỏi dựa trên video vẫn yếu nhất ở mọi cấu hình đã đo và nguyên nhân chưa được kiểm chứng (**Mục 4.6**).

Đóng góp của khóa luận vì thế nằm ở ba điểm: một hệ thống chạy cục bộ, được thiết kế hướng tới thiết bị có bộ nhớ hạn chế, cho phép truy xuất và trích dẫn trên học liệu đa định dạng; một quy trình đánh giá truy xuất có thể tái lập và không rò rỉ dữ liệu; và một bộ kết quả ban đầu được báo cáo trung thực, kèm các hạn chế và trạng thái của những thí nghiệm còn lại.

5.2 Hướng phát triển

Dựa trên kết quả đạt được và các hạn chế đã nêu (**Mục 3.9**), chúng tôi đề xuất các hướng phát triển sau.

Hoàn thiện đánh giá. Kho học liệu nay đã đạt độ phủ 100% đối với bộ câu hỏi đánh giá, các so sánh giữa ba cấu hình truy xuất đã được phân tích bằng lấy mẫu lại ghép cặp, và phân sinh câu trả lời cùng ngữ cảnh truy xuất đã được đánh giá theo khung RAGAs [8] (**Chương 4**). Việc còn lại là: thực hiện các thí nghiệm loại trừ (ablation study) bổ sung (không lọc theo môn học, mở rộng/nén ngữ cảnh, đổi hằng số RRF, gán trọng số theo danh sách) để xác định thêm thành phần nào ảnh hưởng đến kết quả; đo biến thể bất đồng thời HyDE và vòng lặp truy xuất lặp lại; và mở rộng đánh giá sinh câu trả lời sang nhánh trả lời bằng ảnh, đồng thời phân tích riêng sự phân bố điểm của các chỉ số RAGAs (**Mục 4.5.5**).

Hợp nhất thích nghi. RRF chỉ dùng thứ hạng và coi mọi danh sách như nhau [5], trong khi khảo sát về RAG đa phương thức xem hợp nhất là một thành phần riêng của hệ thống [1]. Một hướng phát triển là gán trọng số cho từng nguồn theo loại

câu hỏi và theo độ tin cậy của nguồn (ví dụ độ tin cậy của phiên âm và của nhận dạng ký tự), điều này đòi hỏi bổ sung siêu dữ liệu độ tin cậy cho từng đơn vị tri thức. Hướng này chưa được hiện thực.

Xếp hạng lại và biểu diễn đa phương thức. Việc xếp hạng lại bằng mô hình xét đồng thời câu hỏi và đoạn văn đã được áp dụng cho truy xuất đoạn văn [25]; hệ thống đã tích hợp và đánh giá Qwen3-Reranker [34], cho kết quả vượt hệ thống cơ sở (**Chương 4**). Bộ xếp hạng lại hiện chỉ áp dụng cho danh sách đã hợp nhất, không phân biệt theo loại nội dung hay theo nguồn; họ Qwen3-VL cũng có mô hình xếp hạng lại đa phương thức đi kèm mô hình biểu diễn [21], có thể được thử nghiệm riêng cho các kết quả dạng ảnh.

Truy xuất trực tiếp trên ảnh trang và trên video. Các công trình truy xuất trực tiếp trên ảnh trang tài liệu [9, 33, 30] và truy xuất ở mức video [17] gợi ý các hướng khai thác thị giác đầy đủ hơn so với việc chỉ đưa khung hình đã chọn vào chỉ mục và chỉ đưa ảnh trang vào bước sinh.

Siêu dữ liệu học tập và đồ thị tri thức. Lược đồ siêu dữ liệu hiện chỉ có môn học, loại nội dung và vị trí. Có thể mở rộng lược đồ, tham khảo tiêu chuẩn LOM [16], bằng các trường như chương, tuần, mục tiêu học tập, độ khó và phiên bản học liệu (danh sách trường này là đề xuất của chúng tôi, không phải danh sách nêu trong tiêu chuẩn), và liên kết các nguồn về cùng một khái niệm bằng một đồ thị tri thức; một cách làm đã được đề xuất là dựng đồ thị thực thể từ tài liệu rồi tóm tắt sẵn theo cộng đồng các thực thể gần nhau để trả lời các câu hỏi tổng quát [6].

Hỗ trợ bài tập và kiểm soát đáp án. Bài tập hiện được xử lý như văn bản thông thường. Một trợ lý học tập cần cân nhắc việc không tiết lộ lời giải: CodeAid là một ví dụ về trợ lý lập trình dựa trên mô hình ngôn ngữ lớn (Large Language Model - LLM) được thiết kế để đưa ra phản hồi đúng kỹ thuật mà không tiết lộ mã lời giải [19]. Việc tách đề, gợi ý, lời giải và mức độ khó, cùng cơ chế phân quyền theo vai trò người dùng và trạng thái bài tập, là hướng mở rộng cho hệ thống của chúng tôi.

Triển khai. Dịch vụ hiện chạy trong một tiến trình và xử lý tuần tự từng yêu cầu suy luận; để phục vụ nhiều người học đồng thời cần tách tiến trình suy luận khỏi tiến trình phục vụ và quản lý hàng đợi yêu cầu.

TÀI LIỆU THAM KHẢO

- [1] Mohammad Mahdi Abootorabi et al. “Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation”. In: *Findings of the Association for Computational Linguistics: ACL 2025*. Vienna, Austria, 2025, pp. 16776–16809. arXiv: 2502.08826. url: <https://aclanthology.org/2025.findings-acl.861/>.
- [2] Christoph Auer et al. *Docling Technical Report*. 2024. arXiv: 2408.09869.
- [3] Shuai Bai et al. *Qwen3-VL Technical Report*. 2025. arXiv: 2511.21631.
- [4] Wenhui Chen et al. “MuRAG: Multimodal Retrieval-Augmented Generator for Open Question Answering over Images and Text”. In: *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing (EMNLP 2022)*. 2022. arXiv: 2210.02928.
- [5] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. “Reciprocal rank fusion outperforms condorcet and individual rank learning methods”. In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2009, pp. 758–759. doi: 10.1145/1571941.1572114.
- [6] Darren Edge et al. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization*. 2024. arXiv: 2404.16130.
- [7] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.
- [8] Shahul Es et al. “RAGAs: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*. Association for Computational Linguistics, 2024, pp. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.
- [9] Manuel Faysse et al. “ColPali: Efficient Document Retrieval with Vision Language Models”. In: *International Conference on Learning Representations (ICLR 2025)*. 2025. arXiv: 2407.01449.

- [10] George W. Furnas et al. “The vocabulary problem in human-system communication”. In: *Communications of the ACM* 30.11 (1987), pp. 964–971. doi: 10.1145/32206.32212.
- [11] Luyu Gao et al. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. In: *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2023, pp. 1762–1777. doi: 10.18653/v1/2023.acl-long.99.
- [12] Sensen Gao et al. “Scaling Beyond Context: A Survey of Multimodal Retrieval-Augmented Generation for Document Understanding”. In: *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2026, pp. 4458–4489. doi: 10.18653/v1/2026.acl-long.204. arXiv: 2510.15253.
- [13] Yunfan Gao et al. *Retrieval-Augmented Generation for Large Language Models: A Survey*. 2023. arXiv: 2312.10997.
- [14] Ruslan Gokhman, Jialu Li, and Youshan Zhang. *Automatic Teaching Platform on Vision Language Retrieval Augmented Generation*. 2025. arXiv: 2503.05464.
- [15] Yupan Huang et al. “LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking”. In: *ACM Multimedia 2022*. 2022. arXiv: 2204.08387.
- [16] IEEE Standards Association. *IEEE Standard for Learning Object Metadata*. Tech. rep. IEEE Std 1484.12.1-2020. IEEE, 2020. url: <https://standards.ieee.org/ieee/1484.12.1/7699/>.
- [17] Soyeong Jeong et al. “VideoRAG: Retrieval-Augmented Generation over Video Corpus”. In: *Findings of the Association for Computational Linguistics: ACL 2025*. 2025, pp. 21278–21298. doi: 10.18653/v1/2025.findings-acl.1096.
- [18] Vladimir Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020)*. 2020. arXiv: 2004.04906.
- [19] Majeed Kazemitabaar et al. “CodeAid: Evaluating a Classroom Deployment of an LLM-based Programming Assistant that Balances Student and Educator Needs”. In: *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. 2024. doi: 10.1145/3613904.3642773. arXiv: 2401.11314.

- [20] Patrick Lewis et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In: *Advances in Neural Information Processing Systems (NeurIPS 2020)*. 2020. arXiv: 2005.11401.
- [21] Mingxin Li et al. *Qwen3-VL-Embedding and Qwen3-VL-Reranker: A Unified Framework for State-of-the-Art Multimodal Retrieval and Ranking*. 2026. arXiv: 2601.04720.
- [22] Zongxi Li et al. “Retrieval-augmented generation for educational application: A systematic survey”. In: *Computers and Education: Artificial Intelligence* 8 (2025), p. 100417. doi: 10.1016/j.caeai.2025.100417.
- [23] Yu. A. Malkov and D. A. Yashunin. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (2020), pp. 824–836. doi: 10.1109/TPAMI.2018.2889473.
- [24] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008. url: <https://nlp.stanford.edu/IR-book/>.
- [25] Rodrigo Nogueira and Kyunghyun Cho. *Passage Re-ranking with BERT*. 2019. arXiv: 1901.04085.
- [26] Alec Radford et al. “Robust Speech Recognition via Large-Scale Weak Supervision”. In: *Proceedings of the 40th International Conference on Machine Learning*. Vol. 202. Proceedings of Machine Learning Research. 2023, pp. 28492–28518. arXiv: 2212.04356.
- [27] Stephen Robertson and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* (2009). doi: 10.1561/15000000019.
- [28] Ray Smith. “An Overview of the Tesseract OCR Engine”. In: *Proceedings of the Ninth International Conference on Document Analysis and Recognition (ICDAR)*. IEEE Computer Society, 2007, pp. 629–633.
- [29] Mark D. Smucker, James Allan, and Ben Carterette. “A comparison of statistical significance tests for information retrieval evaluation”. In: *Proceedings of the Sixteenth ACM Conference on Information and Knowledge Management (CIKM)*. 2007, pp. 623–632. doi: 10.1145/1321440.1321528.
- [30] Ryota Tanaka et al. “VDocRAG: Retrieval-Augmented Generation over Visually-Rich Documents”. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR 2025)*. 2025. arXiv: 2504.09795.

- [31] Thomas Tanner, Andreas Marfurt, et al. “Enhancing Question Answering in Lecture Videos with a Multimodal Retrieval-Augmented Generation Framework”. In: *Artificial Intelligence: Methodology, Systems, and Applications*. Lecture Notes in Computer Science. Springer Nature Switzerland, 2025, pp. 184–198. doi: 10.1007/978-3-031-81542-3_15.
- [32] An Yang et al. *Qwen3 Technical Report*. 2025. arXiv: 2505.09388.
- [33] Shi Yu et al. “VisRAG: Vision-based Retrieval-augmented Generation on Multi-modality Documents”. In: *International Conference on Learning Representations (ICLR 2025)*. 2025. arXiv: 2410.10594. url: <https://openreview.net/forum?id=zG459X3Xge>.
- [34] Yanzhao Zhang et al. *Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models*. 2025. arXiv: 2506.05176.